

西安交通大学

硕士学位论文

面向图像分类和目标检测的可迁移对抗攻击算法研究

学位申请人：陈美全

指导教师：

类别（领域）：工程硕士（软件工程）

2025 年 4 月

Research on Transferable Adversarial Attack Algorithms for Image Classification and Object Detection

A thesis submitted to
Xi'an Jiaotong University
in partial fulfillment of the requirements
for the degree of
Master of Engineering

By
Meiquan Chen
Supervisor:
Master of Engineering(Software Engineering)
April 2025

硕士学位论文答辩委员会

面向图像分类和目标检测的可迁移对抗攻击算法研究

答辩人：

答辩委员会委员：

西安交通大学教授： X X (主席)

西安交通大学副教授： XXX

西安交通大学教授： XXX

西安交通大学副教授： XXX

答辩时间：2024 年 04 月 02 日

答辩地点：西安交通大学创新港校区

摘 要

深度学习技术已在多领域取得突破性进展，基于神经网络的图像分类与目标检测模型在检测精度与计算效率方面取得重要突破。然而，随着深度模型在自动驾驶、安防监控及生物识别等安全敏感场景的广泛应用，其脆弱性引发的安全隐患引发高度关注。研究表明，对抗样本对神经网络构成严重威胁，而当前在图像分类与目标检测领域，模型的鲁棒性评估方法与可迁移对抗样本生成机制仍有待深入探索。本文针对图像分类模型和目标检测模型的鲁棒性缺陷，系统性地开展对抗样本黑盒迁移对抗攻击方法研究，主要研究内容包括：

(1) 研究了图像分类模型的对抗样本鲁棒性问题，提出了一种基于快速平坦近邻采样的图像分类可迁移对抗攻击算法（FFSA）。基于局部平坦极大值理论，使用一种新的基于梯度优化的方式生成对抗样本。通过惩罚梯度范数推动对抗样本达到损失局部平坦极大值，简化了每个迭代中随机采样平均梯度的计算方式，缓解了对抗样本对于白盒模型的过拟合现象，同时大大减少了计算复杂度。创新性地设计动态邻域调整机制，对每次随机采样点周围子区域的上界进行随机调整，避免了固定上界造成的邻域信息损失，增强了迁移能力。

(2) 研究了目标检测模型的对抗样本鲁棒性问题，提出了一种基于增强特征失真的目标检测可迁移对抗攻击算法（EFDA）。基于检测器图像特征的空间一致性和有限等变性理论，使用基于增强特征失真的方法生成对抗样本，构建了双路径特征失真度量框架和基于 SRR 的输入变换。前者定义了一个包含幅度失真项和方向失真项的损失函数，衡量对抗样本和原始图像在检测器骨干网络中间层特征的差异。SRR 集成了四种图像变换方式，包括随机网格打乱、随机轴旋转、自适应随机大小调整和高斯模糊，通过使用不同的输入变换，扭曲对象重要特征。两部分结合进一步增强了对抗样本的迁移能力。

综上所述，本文围绕神经网络模型的脆弱性和鲁棒性问题进行深入研究，有针对性的提出了两种迁移对抗攻击，分别针对图像分类模型和目标检测模型。通过提出基于快速平坦近邻采样的图像分类可迁移对抗攻击算法和基于增强特征失真的目标检测可迁移对抗攻击算法，两者互为补充，共同构成了一个强大的黑盒迁移攻击框架，能够对常见的图像分类模型和目标检测模型的鲁棒性进行评估，为安全敏感领域深度学习的应用提供了可靠的安全性分析手段。

关 键 词： 对抗样本；对抗攻击；目标检测；鲁棒性

论文类型： 应用研究

ABSTRACT

In recent years

KEY WORDS: Adversarial examples; Adversarial attacks; Object detection; Robustness

TYPE OF DISSERTATION: Application Research

目 录

摘 要.....	I
ABSTRACT	II
1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 图像分类与对抗样本攻击.....	2
1.2.2 目标检测与对抗样本攻击.....	4
1.3 主要研究内容和理论创新	7
1.4 组织架构.....	8
2 相关理论基础.....	9
2.1 图像分类与对抗样本攻击	9
2.2 目标检测与对抗样本攻击	11
2.3 对抗样本可解释性理论.....	15
2.3.1 模型结构维度分析.....	15
2.3.2 数据驱动维度分析.....	16
2.4 本章小结.....	17
3 基于快速平坦近邻采样的图像分类可迁移对抗攻击.....	18
3.1 问题与挑战	18
3.2 算法设计	18
3.2.1 算法概述.....	18
3.2.2 平坦局部极小值.....	18
3.2.3 梯度范数与平坦局部极大值	20
3.2.4 快速平坦近邻采样对抗样本攻击.....	23
3.2.5 对抗样本损失曲面可视化.....	25
3.3 实验与结果分析.....	28
3.3.1 对比算法.....	28
3.3.2 实验设置.....	29
3.3.3 单模型迁移攻击实验	30
3.3.4 集成模型迁移攻击实验.....	31
3.3.5 与输入变换结合的攻击实验	32

3.4 本章小结	33
4 基于增强特征失真的目标检测可迁移对抗攻击	35
4.1 问题与挑战	35
4.2 目标检测对抗样本迁移性分析	35
4.3 算法设计	37
4.3.1 算法概述	37
4.3.2 针对内部特征的对抗攻击	38
4.3.3 双路径特征失真度量框架	40
4.3.4 基于 SRR 的输入变换	43
4.3.5 对抗样本可解释性分析	45
4.4 实验与结果分析	48
4.4.1 数据集	48
4.4.2 对比方法	48
4.4.3 实验设定	48
4.4.4 评价指标	49
4.4.5 攻击结果可视化分析	51
4.4.6 性能比较与分析	51
4.4.7 消融实验	53
4.5 本章小结	53
5 总结与展望	55
5.1 全文总结	55
5.2 未来工作展望	56
致 谢	57
参考文献	58
攻读学位期间取得的研究成果	64
答辩委员会会议决议	65
常规评阅人名单	66
声 明	

CONTENTS

ABSTRACT (Chinese)	I
ABSTRACT (English)	II
1 Preface.....	1
1.1 Research Background and Significance	1
1.2 Research Status	2
1.2.1 Adversarial Example Attack for Image Classification.....	2
1.2.2 Object Detection	4
1.3 Main Content and Research Innovation	7
1.4 Organizational Structure.....	8
2 Relevant Theoretical Basis	9
2.1 Adversarial Example Attack for Image Classification	9
2.2 Adversarial Example Attack for Object Detection.....	11
2.3 Theoretical of Adversarial Examples Interpretability	15
2.3.1 model architecture analysis.....	15
2.3.2 data-driven analysis.....	16
2.4 Chapter Summary	17
3 Transferable Adversarial Attacks for Image Classification Through Fast Flat Neighborhood Sampling	18
3.1 Problems and Challenges.....	18
3.2 Algorithm Design	18
3.2.1 Overview of the Algorithm.....	18
3.2.2 Flat Local Minima	18
3.2.3 Gradient Norm and Flat Local Maxima.....	20
3.2.4 Fast Flat Neighborhood Sampling Adversarial Attack	23
3.2.5 Visualization of Loss Surfaces for Adversarial Example.....	25
3.3 Analyse of Experiment	28
3.3.1 Comparison Algorithms.....	28
3.3.2 Experimental Settings	29
3.3.3 Transferability Attack Experiments on Single Models	30
3.3.4 Transferability Attack Experiments on Ensemble Models	31

3.3.5 Attack Experiments Combined with Input Transform	32
3.4 Summary	33
4 Transferable Adversarial Attacks for Object Detection Through Enhancing Feature Distortion	35
4.1 Problems and Challenges.....	35
4.2 Analysis of the Transferability of Adversarial Samples in Object Detection	35
4.3 Algorithm Design	37
4.3.1 Overview of the Algorithm.....	37
4.3.2 Experimental Settings	38
4.3.3 Algorithmic Procedure	40
4.3.4 Input Transformation Based on SRR.....	43
4.3.5 Analysis of the Interpretability of Adversarial Examples	45
4.4 Experiments and Results Analysis	48
4.4.1 Datasets	48
4.4.2 Comparison Methods.....	48
4.4.3 Experimental Settings	48
4.4.4 Evaluation Metrics.....	49
4.4.5 Visualization Analysis of Attack Results	51
4.4.6 Performance Comparison and Analysis.....	51
4.4.7 Ablation Studies.....	53
4.5 Summary	53
5 Conclusion and Prospect.....	55
5.1 Conclusion	55
5.2 Prospect of Future Work.....	56
Acknowledgements.....	57
References	58
Achievements	64
Desicion of Defense Committee	65
General Reviewers List	66
Declarations	

1 绪论

1.1 研究背景及意义

深度学习作为人工智能领域最具突破性的技术之一，通过模仿人脑神经网络构建多层次计算模型，实现了从海量数据中自动提取复杂特征的能力。自 2006 年 Geoffrey Hinton 团队提出深度置信网络（Deep Belief Networks, DBN）这一关键算法框架以来，该领域迎来重大转折。2012 年其团队采用深度卷积神经网络（CNN）在 ImageNet 图像分类竞赛中取得突破性成果，不仅验证了深度学习的技术优势，更引发了学术界与产业界的广泛关注。随着计算能力的提升和大数据时代的到来，深度学习展现出强大的应用潜力：在技术层面，通过端到端特征学习机制，其处理视觉识别、语言理解等复杂任务的准确率已超越传统方法。在计算机视觉领域，目标检测技术的演进尤为显著。相较于传统基于手工特征的方法，深度学习通过区域建议网络与特征金字塔等创新架构，实现了对图像中多尺度目标的精准定位与分类。以 Faster R-CNN、YOLO 系列为代表的模型，将目标检测的精度与实时性提升至新高度，成为自动驾驶环境感知、智能安防监控等场景的核心技术支撑。在应用层面，深度学习已渗透至医疗诊断（如医学影像分析）、金融科技（风险评估建模）、智能交通（自动驾驶决策系统）以及自然语言处理（语音交互系统）等多个领域。特别是在计算机视觉方向，深度学习推动了图像分类、目标检测、人脸识别等核心任务的技术革新，持续刷新各领域性能基准。这种通过多层次非线性变换实现数据表征学习的技术范式，不仅为复杂问题提供了新的解决路径，更重塑了人工智能技术的应用格局，成为推动当代智能化转型的核心驱动力。

然而，深度学习在取得突破性进展的同时，其安全脆弱性正成为制约技术落地的关键瓶颈。神经网络固有的“黑盒”特性导致模型决策过程缺乏可解释性，这种不透明性为对抗攻击提供了可乘之机——攻击者通过向输入数据注入人眼不可感知的细微扰动（即对抗样本），即可使深度学习系统产生致命误判。2016 年特斯拉自动驾驶汽车将白色货车误判为天空云朵导致的重大事故，正是此类脆弱性的现实映射。在自动驾驶、人脸识别等高风险场景中，对抗样本可能引发交通信号误识别、非法用户认证通过等系统性风险，严重威胁关键基础设施安全。研究发现，使用对抗样本生成的交通标识，能够欺骗自动驾驶系统的感知模型，从而引发严重的交通问题。这种安全困境不仅暴露了深度学习模型的理论缺陷，更直接阻碍了其在金融、医疗、国防等敏感领域的实际部署。当前目标检测技术面临双重挑战：一方面，对于图像分类模型的鲁棒性研究不足，对其安全缺陷了解不够深入；另一方面，针对目标检测模型的对抗样本生成技术的演进使得攻击更具隐蔽性和破坏性，当前对其攻击可迁移性的研究较少。因此需要对深度神经网络模型的鲁棒性和对抗样本的生成机理做进一步的深入研究。

1.2 国内外研究现状

1.2.1 图像分类与对抗样本攻击

深度学习对抗样本攻击是一种针对人工智能系统的安全威胁手段，核心在于通过在深度学习模型的输入数据中添加一些精心构建的扰动，从而诱导模型产生期望之外的错误输出。这些经过特殊设计的干扰数据称为对抗样本，其构造过程通常涉及对模型内部结构信息的逆向分析。同时由于这些扰动的修改范围被严格限定在很小范围，人类视觉系统几乎无法察觉其存在。对抗样本的存在表明深度学习模型的安全性仍有待提高，这严重阻碍了人工智能技术在现实生产生活中的广泛部署和应用。

从攻击目标预设维度划分，对抗攻击算法可分为非定向攻击和定向攻击两种范式。非定向型算法以诱导模型误判为基本目的，而定向型算法需要精确设定被攻击目标，通过对抗扰动引导模型输出预设的错误预测结果。研究数据表明，前者因约束条件较少更容易实施，后者则凭借明确的误导指向性在特定攻防场景中更具有价值。

根据攻击者对于目标模型结构的了解层次，对抗攻击可以分为白盒攻击和黑盒攻击两大类。发起白盒攻击需要完全了解目标模型内部参数和结构，这使得它们在现实世界环境中不太实用，但可以通过准确的模型结构信息对神经网络薄弱处进行定位，从而构造出更强大的攻击模式。Szegedy 等人^[1]在 2014 年提出了对抗样本（Adversarial Examples）的概念，通过 L-BFGS 算法构造对抗样本攻击神经网络模型取得成功，使得模型对于图片分类结果出错。Szegedy 等人认为模型错误分类是神经网络的非线性导致的。

随后 Goodfellow 等人^[2]在 2015 年提出了快速梯度符号攻击方法（Fast Gradient Sign Method, FGSM），通过在图像中添加基于梯度方向的扰动对模型进行攻击。在此基础上 Kurakin 等人^[2]提出了 FGSM 的进化版本迭代快速梯度符号攻击方法（Iterative Fast Gradient Sign Method, I-FGSM），多次添加基于梯度方向的扰动，进一步提高对抗攻击能力。Madry 等人^[3]使用投影梯度下降法（Projected Gradient Descent, PGD）引入随机初始化以进一步增强攻击性能。Moosavi 等人^[4]找到一种方法 DeepFool，引导干净样本越过决策边界，这在每次迭代中表征多面体的最近边界，并显示出提供更小扰动的能力。Carlini 和 Wagner（C&W）攻击^[5]提供了一个新的目标函数，以更好地适应优化，它有一个额外的项来控制找到的对抗样本的置信度，并且可以通过二分搜索和 Adam 优化器解决。上述攻击方法产生的扰动都依赖于原始图像，即每个良性样本都与一个独特的扰动相结合。除此之外，在通用对抗扰动（UAP）^[6]中研究了与图像无关的对抗扰动的存在性，这是通过查找并聚合将图像集中的大多数图像发送到各自决策边界的扰动向量而产生的。

虽然对抗样本的存在引起了人们对机器学习系统的鲁棒性和可靠性的担忧，但研究人员发现了一个更加有趣的现象：对抗样本的可迁移性^[7]。可迁移性是指为一个模型设计的对抗样本成功欺骗不同模型的能力，通常是具有不同架构的模型。利用这样的

属性,可以在不访问目标模型的任何细节(例如模型架构、模型参数和训练数据)的情况下成功实施攻击。这样的对抗攻击称为黑盒攻击,黑盒表明攻击者完全不了解目标模型的内部结构和参数。

实现黑盒对抗性攻击的一种方法是从查询数据中估计梯度,称为基于查询的攻击,包括边界攻击^[8]、集成对抗训练^[9]和SPSA^[10]等方法。然而,在实践中这些基于查询的攻击通常受到有限的可能查询数量的限制。因此,提出了基于迁移的攻击,对本地代理模型采用白盒攻击,并利用对抗性示例的可迁移性来攻击目标模型。

与训练神经网络的过程类似,生成对抗样本的过程也可以视为一个优化问题。在优化阶段,被攻击来优化对抗样本的白盒模型可以被看作是训练过程中的训练数据。对抗样本可以被看做模型的训练参数。在测试阶段,被用来评估对抗样本的黑盒模型可以被视为模型的测试数据。从优化的视角来看,对抗样本的可迁移性与训练模型的泛化能力相似。因此,可以将用于提高模型泛化性的方法迁移到对抗样本的生成上,从而提高对抗样本的可迁移性。许多方法已经被提出用于提高深度学习模型的泛化性能,这些方法可以分为两类:1)更好的优化算法,如Adam优化器^[11];2)数据增强^[12]。基于这种思想,与之相对应的黑盒攻击可以分为四种类型:基于输入变换的攻击、基于梯度修正的攻击、基于内部特征的攻击和基于生成模型的攻击。近些年来,有许多生成可迁移对抗攻击的方法被提出,总结如下:

(1) 基于输入变换的攻击 (Input Transformation based Attack): 数据增强已被证明对提高模型泛化是有效的,也有很多提高对抗可移植性的研究,例如随机调整大小和填充 (DIM)^[13]、随机缩放 (SIM)^[14] 和对抗性混合 (Adversarial Mixup, Admix)^[15]。除此之外 Dong 等人^[16] 使用一组翻译过的图像来计算梯度,并取得对防御模型更好的性能表现。期望变换方法 (Expectation of Transformation, EOT) 在选定的变换分布上合成对抗样本,从而增强对抗迁移性。

(2) 基于梯度修正的攻击 (Gradient Modification based Attack): 与 I-FGSM 不同, Dong 等人^[17] 的工作将动量集成到梯度更新策略中,即 MI-FGSM。在动量基础上, Lin 等人^[14] 使用 Nesterov 加速梯度来提高对抗迁移性,即 NI-FGSM。Wang 和 He 等人^[18] 通过微调每个梯度步长的方差找到一种更加稳定的梯度方向,同时这种方差调整可以与之前两个工作结合起来分别称为 VMI-FGSM 和 VNI-FGSM。还有一些特定于模型的设计用来提高对抗可迁移性。例如, Wu 等人^[19] 发现跳过连接的梯度 (Skip Gradient Method, SGM) 对于生成迁移性更高的攻击更为关键。类似的, Guo 等人提出了 LinBP 在反向传播期间利用更多的跳过连接梯度。然而这些方法往往特定于模型架构,例如跳过连接,将这些方法扩展到其他模型或者结构尤为重要。

(3) 基于内部特征的攻击 (Intermediate Feature based Attack): 除了在输出层生成对抗样本外,一些研究还关注了内部层的特征。Hong 等人^[20] 和 Inkawhich 等人^{[21][22]} 提出利用特征空间约束来生成更强的迁移攻击,然而者需要识别性能最好的中间层或者为所有受攻击的类训练 one-vs-all 的二分类器。Zhao 等人^[23] 发现具有更多迭代次数的攻击和 logit 损失可以实现相对较高的有目标迁移性,并超过基于特征的攻击。Zhang 等

人^[24]和 Naseer 等人^[25]分别提出了 TAP 和 NRDM, 通过最大化对抗图像和良性图像之间的特征距离来扰动中间层特征可以增强对抗迁移能力。Inkawich 等人提出 FDA^[9], 通过通道上的平均值来划分元素属性, 抑制高于平均值的元素并放大低于平均值的元素。Lu 等人提出 FVA^[26], 通过减少特征方差来实现对抗攻击, 与其他方法有相似之处。FIA^[27]、RPA^[28]和 NAA^[29]结合标签信息以获得聚合梯度, 从而能够准确测量特征重要性并增强对抗攻击的迁移能力。

(4) 基于生成模型的攻击 (Generative Models based Attack): 还有一些方法^{[30][31][32]}利用生成模型产生对抗扰动。例如 Naseer 等人^[32]的工作提出训练一个生成模型以匹配初始类和目标类的分布, 从而增加有目标可迁移性。然而, 扰动生成器的学习并不容易, 尤其是在大规模的数据集上。

由于对抗样本可以帮助衡量模型的鲁棒性, 并且可以通过对抗性训练提高模型的鲁棒性, 因此对如何生成具有高迁移性的对抗样本进行研究非常重要。

1.2.2 目标检测与对抗样本攻击

目标检测 (Object Detection, OD) 旨在搜索输入图像 (或视频) 中目标的位置, 并找出该目标的类别类型。传统的目标检测方法基于滑动窗口方法从原始输入中提取特征, 然后通过传统的机器学习框架 (例如, SVM^[33]) 训练特征分类器。然而, 传统目标检测方法的性能受到其数学模型和难以捉摸的参数限制, 这意味着其应用范围因优化一些复杂的数学问题而缩小, 因为可能存在一些 NP 难问题阻碍了参数的寻找 (NP 问题是指可以在多项式的时间里验证一个解的问题)。另一方面, 与传统的深度学习方法相比, 传统模型的性能可能过于僵化。由于训练数据的限制, 传统方法可能缺乏预测未知类别的能力, 而基于各种和足够数据的深度学习方法具有更好的泛化能力。因此, 用基于深度学习的方法取代传统方法是一个不可避免的趋势。

目标检测模型通常由以下几个关键组件构成:

(1) 输入模块 (Input): 负责接收和预处理输入的图像数据, 将其转换为适合模型处理的格式。常见实现: 使用数据加载器 (如 PyTorch 的 DataLoader) 来读取图像文件, 并进行如归一化、裁剪、缩放等预处理操作, 以确保输入数据的一致性和模型的稳定性。

(2) 主干网络 (Backbone): 作为模型的核心部分, 主干网络负责从输入图像中提取特征, 生成特征图。常见实现: 通常采用深度卷积神经网络 (CNN), 如 ResNet、VGG、EfficientNet 等。这些网络通过多层卷积操作自动学习图像中的边缘、纹理、形状等特征, 为后续的目标检测提供基础。

(3) 颈部网络 (Neck): 连接主干网络和检测头, 用于优化和重新配置主干网络提取的原始特征数据, 以更好地适应检测任务的需求。常见实现: 特征金字塔网络 (FPN) 是最常用的颈部网络结构之一, 它通过自底向上和自顶向下的路径, 将不同层次的特征图进行融合, 生成具有多尺度信息的特征金字塔, 从而提高模型对不同大小目标的检测能力。

(4) 检测头 (Head): 根据颈部网络提供的特征图, 预测目标的位置、大小和类别。常见实现: 单阶段检测器 (如 YOLO 系列): 直接在特征图上预测目标的边界框和类别, 速度快但精度略逊于两阶段检测器。两阶段检测器 (如 R-CNN 系列): 首先生成一系列候选区域 (Region Proposals), 然后对每个候选区域进行分类和边界框回归, 精度高但速度较慢。Anchor-free 检测器 (如 CenterNet、FCOS): 不依赖于预设的锚框 (Anchors), 直接预测目标的中心点或关键点, 简化了检测流程并提高了对小目标的检测能力。基于关键点的方法 (如 CornerNet): 通过检测目标的角点或关键点来预测边界框, 这种方法在处理遮挡和密集目标时具有优势。DETR: 基于 Transformers 的检测头, 不依赖区域提案, 通过自注意力机制实现目标的直接检测, 展现出较好的扩展性。

这些组件共同协作, 使得目标检测模型能够准确地识别和定位图像中的目标物体。不同的模型在这些组件的具体实现上可能会有所不同, 以适应不同的应用场景和需求。

2017 年, He 等人提出了一种特征金字塔结构 (FPN^[34]), 通过对不同尺度的特征图进行自上而下的融合来获取多尺度的上下文信息。受 FPN 的启发, 随后提出了许多新的多尺度融合结构, 如 PANet^[35]、BiFPN^[36]、Generalized-FPN^[37] 等。这些结构可以充分融合深浅特征信息, 提高多尺度目标检测的准确率。

基于深度学习的目标检测方法可以归纳为两大类: 两阶段目标检测算法和一阶段目标检测算法。两阶段目标检测算法通过两个独立的网络来实现检测任务。它对候选框进行初步筛选, 导致检测精度更高。而一阶段目标检测算法只使用一个网络来完成检测任务, 不需要额外的分割或区域提议步骤, 因此检测速度更快。

(1) 两阶段目标检测算法

R-CNN: 具有卷积神经网络的区域^[38]于 2014 年提出, 该算法首次将深度学习用于目标检测任务, 并取得了优异的效果。R-CNN 摒弃了传统的手动特征提取方法, 采用选择性搜索^[39]算法对输入图像上的候选区域进行划分, 然后通过卷积神经网络对每个区域进行分类回归。

Fast RCNN: 快速基于区域的卷积网络^[40]于 2015 年提出, 旨在缓解 R-CNN 计算效率低下的问题。Fast RCNN 利用空间金字塔池网络 (SPPNet^[41]) 的优势来共享卷积参数, 缓解卷积神经网络在 R-CNN 中每个候选区域的缺点, 并将分类和回归任务集成到一个网络中。

Faster R-CNN: 2015 年, Ren 等人推出了 Faster R-CNN^[42], 摆脱了使用选择性搜索算法生成候选区域。相反, Faster R-CNN 引入了区域提议网络, 简化了训练过程, 降低了训练的复杂度。RPN 高效地选择得分高的候选区域, 并通过回归进行微调, 缩小了精确目标检测的搜索空间。Faster R-CNN 是 Fast R-CNN 算法的改进版本, 并取得了一些成果。

(2) 一阶段目标检测算法

YOLO 是 2015 年提出的一种流行的实时目标检测算法。该算法通过将目标检测任务转化为单个神经网络的回归问题并直接对整个图像进行预测来实现快速准确的目标

检测。活在当下采用卷积网络架构将输入图像划分为 $S \times S$ 网格。在每个网格中，它预测 B 个边界框，并估计每个框对应 K 个不同类别的概率。活在当下检测器的主要优点是检测速度快。

2016 年提出了单发多盒检测器 (SSD)，实现了端到端的单一模型来完成目标检测任务，简化了整个检测过程。SSD 提出了默认盒的概念，省去了提案生成和后续的重采样阶段，简化了网络的计算。此外，SSD 首次采用多层特征图进行检测任务，在三种不同尺寸的特征图上进行。不同尺寸的默认盒在不同尺寸的特征图上表示，并将多个不同尺寸的特征图的检测结果进行组合，实现了对不同尺寸的目标的检测。

RetinaNet 于 2017 年提出，它不是通过其网络架构而脱颖而出，而是通过引入一种称为焦点损失的新型损失函数而脱颖而出。RetinaNet 采用 ResNet 作为其基础网络，并结合了特征金字塔网络 (FPN) 进行多尺度特征融合。作者强调，单阶段目标检测方法面临着类别不平衡的重大挑战，特别是前景和背景类别之间样本数的差异。为了解决这个问题，他们建议修改传统的交叉熵损失函数以引入焦点损失。该方法将简单背景样本的学习权重降低到加权形式，并专注于困难样本。

YOLOv3[43] 是 YOLOv2 的改进版本，于 2018 年提出。YOLOv3 在 YOLOv2 的基础上，使其主干更加深入，并利用 Darknet-53 骨干网络提取更丰富的特征，包含 53 个卷积层，通过残差块和下采样层提取图像特征，进一步提高模型的检测性能。此外，增加了跨层连通性，融合了深浅特征图，更充分地利用了不同层的语义信息，进一步提高了对小对象的检测。引入了自适应锚盒设置方法，根据数据集自动调整锚盒的大小和长宽比，使模型更适应不同数据集和场景的对象特征。它将目标检测问题转化为回归问题，直接在特征图上预测边界框和类别概率。YOLOv3 的损失函数包括边界框坐标损失、目标置信度损失和类别预测损失。该模型以速度快、精度高著称，适合实时目标检测任务。

早期针对目标检测器的对抗攻击集中在白盒设置中，其中方法通常受到所使用检测器类型的限制。像 DAG^[44]、RAP^[45] 和 CAP^[24] 这样的攻击专门设计用于利用区域提议网络 (RPN)，并且仅限于基于提议的两阶段目标检测器。尽管 UEA^[46] 攻击可以针对单阶段和双阶段模型，但其局限性在于它仅在有限的黑盒模型集上提供迁移攻击结果。TOG^[47] 可以攻击任何架构的模型，因为训练损失的反向传播是可行的。此外，其他几种方法^[48, 49] 利用对象的共现及其相对位置和大小作为上下文信息来实现可迁移的针对性攻击。这些方法中的大多数主要侧重于通过设计策略扰动检测器模型的输出，只有一小部分利用中间层特征，并且对它们的特性考虑有限。

跨任务的迁移攻击 (Transfer Attacks Cross-task): 虽然像 FDA 这样的攻击在图像分类器上表现出显著的对抗迁移能力，但直接将这些方法应用于检测器并不能产生令人满意的结果，因为它们与检测器特征的特性不匹配。同时，基于梯度聚合的攻击如 RPA 带来了硬件和时间成本，并可能过度拟合复杂的检测器模型结构。因此研究跨任务的迁移攻击对于研究目标检测模型的鲁棒性研究尤为重要。Naseer 等人^[25] 提出了一种新颖的对抗攻击方法 NRDM，该方法采用神经表示失真来生成对抗样本。他们展示了对抗

样本在不同神经网络架构、数据集和任务之间的显著迁移能力。随后，Cross-domain^[30]中的领域不变对抗者的新概念，证明了不同数据集和模型之间存在共享对抗空间。此外，他们提出利用能够欺骗在完全不同领域训练的网络的对抗模式来提高攻击迁移能力。Lu 等人^[50]研究了对抗样本在不同计算机视觉任务之间的迁移能力，包括目标检测、图像分类、语义分割等。然后，他们提出了一种分散减少（DR）对抗攻击方法，该方法最小化中间特征图的扩散，以提高跨任务对抗样本的迁移能力。Wei 等人^[51]研究了不同模态间对抗扰动的迁移能力。具体来说，他们利用图像和视频帧之间低级特征空间的相似性，将对抗样本应用于白盒图像模型来攻击黑盒视频模型。他们提出了一种有效的跨模态攻击方法 I2V，该方法最小化干净图像和对抗图像之间特征的余弦相似性，以增强攻击迁移能力。最近，Naseer 等人^[52]提出 DCViT-AT，采用任务特定的提示将空间（图像）和时间（视频）线索整合到同一源模型中，这可以增强从图像到视频和图像到图像模型的攻击迁移能力。

1.3 主要研究内容和理论创新

本文研究了包括图像分类网络和目标检测网络在内的神经网络模型固有的鲁棒性和安全性问题，对抗样本的产生机理进行了深入分析，基于不同角度分别针对图像分类模型和目标检测模型提出了具有强大迁移能力的对抗攻击算法。主要的工作内容包括：

（1）基于不同的图像分类模型和目标检测模型测试了现有迁移攻击算法的有效性，并完成了对单模型和集成模型的鲁棒性测试。

（2）开展基于快速平坦近邻采样的图像分类可迁移对抗攻击的研究与实现。

（3）开展基于增强特征失真的目标检测可迁移对抗攻击的研究与实现。

本文主要的创新点如下：

（1）基于局部平坦极大值理论，提出了一种新的基于梯度优化的图像分类迁移对抗攻击算法 FFSA，即快速平坦近邻采样对抗攻击。简化了每个迭代中随机采样平均梯度的计算方式，防止对抗样本对于白盒模型的过拟合的同时大大减少了计算复杂度。对每次随机采样点周围子区域的上界进行随机调整，避免了固定上界造成的邻域信息损失，增强了迁移能力。通过广泛的单模型和集成模型实验，有力的证明了该算法比现有的攻击方法具有更高的黑盒迁移攻击能力。同时通过扩展实验，说明本方法可以方便的和其他基于输入变换的方法结合使用进一步提高对抗样本迁移性。通过二维损失曲面可视化进一步证明了理论基础的有效性。

（2）根据目标检测器图像特征的空间一致性和有限等变性理论，提出了一种新的目标检测对抗攻击算法 EFDA，即基于增强特征失真的可迁移对抗攻击，可生成用于无目标攻击的对抗样本。包括两个部分双路径特征失真度量框架和基于 SRR 的输入变换。前者定义了一个包含幅度失真项和方向失真项的损失函数，衡量对抗样本和原始图像之间在检测器 Backbone 中间层特征的差异，通过增强这种差异实现迁移攻击。后

者定义了四种图像变换方式，包括随机网格打乱、随机轴旋转、自适应随机大小调整和高斯模糊，通过使用不同的输入变换，扭曲对象重要特征。通过对 4 种白盒模型与 8 种黑盒模型的广泛的迁移攻击实验，有力的说明了 EFDA 的强大黑盒迁移攻击能力。并通过消融实验验证了 SRR 所提出的各种输入变换方法的有效性。

1.4 组织架构

本文针对对抗样本相关问题展开研究，内容共分为五章，研究框架如图??所示。各章的组织安排如下：

第一章：首先介绍本文的研究背景与意义，概述对抗样本的产生机理，以及图像分类对抗攻击和目标检测对抗攻击的分类和经典算法。

第二章：介绍对抗样本相关的理论基础与研究现状，详细介绍现有的针对图像分类模型和目标检测模型的白盒攻击和黑盒攻击的分类方法和代表工作。同时在对抗样本的形成机制和可解释性方面，从模型结构角度和数据分布角度进行了探讨。

第三章：提出了一种新的基于梯度优化的图像分类迁移对抗攻击算法 FFSA，即快速平坦近邻采样对抗攻击。首先对平坦局部极小值和梯度范数等概念进行介绍，通过惩罚梯度范数使得对抗样本到达平坦极大值区域。然后针对现有算法的问题提出了快速平坦近邻采样对抗攻击，并通过对比实验和扩展实验验证有效性，通过二维损失曲面可视化进行可解释分析。

第四章：提出了一种新的目标检测对抗攻击算法 EFDA，即基于增强特征失真的可迁移对抗攻击，包括两个部分双路径特征失真度量框架和基于 SRR 的输入变换。通过对比实验和消融实验证明了算法的有效性。最后实验 Grad-CAM 方法对生成的对抗样本进行可解释分析，证明了所提出方法可以有效改变模型对于图像目标的注意力。

第五章：首先对本文研究内容做总结分析，然后对已有工作的不足提出改进方向，对未来研究方向进行展望。

2 相关理论基础

2.1 图像分类与对抗样本攻击

对于白盒攻击，给定一个输入图像 x 及其对应的真实标签 y ，具有参数 θ 的深度模型 f 应该以高概率输出预测 $f(x; \theta) = y$ 。令 $\mathcal{B}_\epsilon(x) = \{x' : \|x' - x\|_p \leq \epsilon\}$ 为输入图像 x 临近区域的一个 ϵ 球，其中 $\epsilon > 0$ 是预定义的扰动幅度， $\|\cdot\|_p$ 表示 L_p 范数（例如， L_1 范数）。攻击者的目标是找到一个添加了扰动的图像 $x^{adv} \in \mathcal{B}_\epsilon(x)$ ，使得分类器 $f(x^{adv}; \theta) \neq y$ 。令 $J(x, y; \theta)$ 为分类器 f 的损失函数（例如，交叉熵损失）。现有的白盒攻击如 [2, 17, 53] 通常通过解决以下最大化问题来生成对抗样本：

$$\max_{x^{adv} \in \mathcal{B}_\epsilon(x)} J(x^{adv}, y; \theta). \quad (2-1)$$

这些攻击方法主要通过梯度迭代生成对抗样本。FGSM^[53] 找到一个满足 $x^{adv} \in \mathcal{B}_\epsilon(x)$ 的对抗样本 x' ，使用以下公式：

$$x^{adv} = x + \epsilon \cdot \text{sign}(\nabla_x J(x, y)) \quad (2-2)$$

其中 $\nabla_x J(x, y)$ 表示代价函数关于输入 x 的梯度。 J 的一个常见选择是交叉熵。在此基础上，I-FGSM^[2] 迭代更新对抗扰动如下：

$$x_{t+1}^{adv} = \Pi_{\mathcal{B}_\epsilon(x)} \left[x_t^{adv} + \alpha \cdot \text{sign}(\nabla_{x_t^{adv}} J(x_t^{adv}, y; \theta)) \right], \quad x_0^{adv} = x, \quad (2-3)$$

其中 $\Pi_{\mathcal{B}_\epsilon(x)}(\cdot)$ 将输入投影到 $\mathcal{B}_\epsilon(x)$ 中， $\alpha = \epsilon/T$ ， T 是总迭代次数。

PGD 攻击^[3] 是 FGSM 的强迭代变体。它由允许的范数球内的随机开始组成，然后通过运行 I-FGSM 的多次迭代来生成对抗性示例。

DeepFool^[4] 提出了一种引导干净示例跨过决策边界的方法，该边界在每次迭代中表征了多面体的最近边界，并被证明可以提供更小的扰动。

Carlini 和 Wagner (C&W) 攻击^[5] 提供了一个新的目标函数来更好地适应优化，该目标函数有一个附加项来控制找到的对抗性示例的置信度，可以通过二分搜索和 Adam 优化器来解决。上述攻击方法产生的扰动都是图像相关的，即每个良性示例都结合了一个独特的扰动。

Moosavi-Dezfooli 等人提出通用对抗扰动 UAP^[6] 使用输入的集成来寻找在深度神经网络和输入中都能泛化的通用扰动。与之前独立计算每个示例的扰动的工作不同，他们聚合原子扰动以减少扰动的变化。他们表明，这种扰动在不同的分类模型中泛化得很好。

一种常见的黑盒攻击是通过基于查询信息（例如概率向量和硬标签）估计梯度来制作对抗性示例，这称为基于查询的攻击。基于查询的攻击在现实世界中可能不切实际，因为不允许过多的查询。相比之下，另一种典型的黑盒攻击，称为基于迁移的攻击，

依赖于对抗性示例的跨模型可移植性（即，在一个模型上制作的对抗性样本可以成功攻击同一任务的其他模型），这更实用和灵活。对于黑盒攻击，目标模型的梯度信息不可访问，因此不能像 I-FGSM 那样直接解决问题。为了解决问题2-1，基于迁移的攻击在可访问的替代模型上生成对抗样本，这些样本可以被用来对目标模型进行欺骗。

给定一个良性样本 $(x, y) \in (\mathcal{X}, \mathcal{Y})$ ，迁移对抗攻击的过程首先是通过攻击白盒代理模型 $\mathcal{M}^s(x; \theta) : \mathcal{X} \rightarrow \mathcal{Y}$ 来在 $\mathcal{X}$ 的邻域区域 $\mathcal{B}_\epsilon(x) = \{x^{adv} : |x^{adv} - x|_p \leq \epsilon\}$ 内构建对抗样本 x^{adv} ，然后将 x^{adv} 迁移到直接攻击黑盒目标模型 $\mathcal{M}^t(x; \phi) : \mathcal{X} \rightarrow \mathcal{Y}$ 。攻击的目标是误导目标模型，即 $\mathcal{M}^t(x^{adv}; \phi) \neq y$ （无目标攻击），或者 $\mathcal{M}^t(x^{adv}; \phi) = y_t$ （有目标攻击），其中 $y_t \in \mathcal{Y}$ 表示目标标签。以有目标攻击为例，许多现有迁移攻击方法的一般公式可以写为：

$$\min_{x^{adv} \in \mathcal{B}_\epsilon(x)} \mathcal{L}(\mathcal{M}^s(\mathcal{G}(x^{adv}); \theta), y_t) \quad (2-4)$$

损失函数 $\mathcal{L}$ 通常被设置为交叉熵（CE）损失 [13] 或者是 logit 损失 [23]，这将在后续实验中具体说明。此外，通过将损失函数 $\mathcal{L}$ 和 y_t 分别替换为 $-\mathcal{L}$ 和 y ，可以很容易得到无目标攻击的公式：

$$\min_{x^{adv} \in \mathcal{B}_\epsilon(x)} -\mathcal{L}(\mathcal{M}^s(\mathcal{G}(x^{adv}); \theta), y) \quad (2-5)$$

在这里，如果令损失函数 $J = -\mathcal{L}$ ，则可以表示为：

$$\max_{x^{adv} \in \mathcal{B}_\epsilon(x)} J(\mathcal{M}^s(\mathcal{G}(x^{adv}); \theta), y) \quad (2-6)$$

由于 $\mathcal{M}^s$ 是白盒的，如果将 $G(\cdot)$ 设置为恒等函数，那么可以采用任何现成的白盒对抗攻击方法来解决（1），例如 I-FSGM [2]，MI-FGSM [17] 等。同时，现有的工作已经设计了不同的 $G(\cdot)$ 函数，并开发了相应的优化算法，以增强替代模型和目标模型之间的对抗迁移能力。例如， $G(\cdot)$ 被指定为随机调整大小和填充（DI）[13]，平移变换（TI）[16]，尺度变换（SI）[14] 和对抗混合（Admix）[15]。

Dong 等人 [17] 的工作在 I-FGSM 的优化目标中加入了动量，即 MI-FGSM。它可以表示如下：

$$\begin{aligned} x_0^{adv} &= x, \quad x_{t+1}^{adv} = x_t^{adv} + \alpha \cdot \text{sign}(g_{t+1}), \quad t \in [1, T] \\ g_{t+1} &= \mu \cdot g_t + \frac{\nabla_x J(x_t^{adv}, y)}{\|\nabla_x J(x_t^{adv}, y)\|_1} \end{aligned} \quad (2-7)$$

其中 g_t 是第 t 次迭代时累积的梯度量， μ 是 g_t 的衰减因子。

也可以使用基于集成的方法来处理输入和架构，以实现跨模型的迁移。另一种类型的工作使用不同架构的集成来实现跨模型迁移，这在竞赛中被广泛使用。从防御的角度来看，Florian 等人 [9] 将从其他预训练模型转移的对抗样本纳入其中，以利用不同架构的集成优势，这提高了深度神经网络对黑盒攻击的鲁棒性。这两种集成方法都鼓励算法搜索共享空间，以减少具有高计算复杂度的扰动变化。这表明对扰动的平滑正

则化可以有效地减少扰动的变化。

2.2 目标检测与对抗样本攻击

深度学习（DL）基础的目标检测方法的第一个关键阶段发生在 Ross 等人提出第一个面向 CNN 的目标检测模型 R-CNN^[38] 时，该模型在 2014 年通过使用神经网络而不是滑动窗口方法提取特征。然而，传统的方向性思维限制了这项工作的分类部分，他们使用 SVM，这与 CNN 框架相比更为复杂。直到 2015 年，Ross 通过利用反向传播（Back Propagation, BP）网络^[54] 进行分类和回归，优化了这一缺陷以构建 Fast R-CNN^[40]，这意味着算法倾向于由 CNN 组成。另一方面，神经网络的优势吸引了更多的研究人员使用 CNN 方法优化他们的工作。由于 CNN 几乎涵盖了目标检测过程的所有阶段，如果有人打算提高效率，就有必要限制这些 CNN 的成本。因此，基于这一理念提出了 YOLO，因为它将涉及 CNNs 结合在一起^[55]。与 Fast R-CNN 相比，它迭代输入图像所需的时间更少。因此，YOLO 可以处理实时视频输入，但准确性下降，这是它获得速度的代价。Ross 等人提出了基于区域提议网络（RPN）的 Faster R-CNN^[42]，以改善 Fast R-CNN 中存在的不足，旨在打破 Fast R-CNN 中选择性搜索算法^[39] 的依赖，如图 2-1 所示。Faster R-CNN 提供了一个完整的基于 CNN 的方法来加速算法，它比 YOLO 具有更高的准确性，因为两个不同的网络分别支持回归和分类。YOLO 和 Faster R-CNN 的产生表明了使用深度学习方法解决目标检测任务的新水平，这激活了该领域的发展。




图 2-1 FRCNN 的网络结构

深度目标检测网络通常具有相似的输入输出结构和类似的公式。给定一个输入图像 x ，目标检测器首先检测到大量的 S 个候选边界框 $\{\hat{o}_1, \hat{o}_2, \dots, \hat{o}_S\}$ ，其中 $\hat{o}_i = (\hat{b}_i^x, \hat{b}_i^y, \hat{b}_i^W, \hat{b}_i^H, \hat{C}_i, \hat{p}_i)$ 是一个以 $(\hat{b}_i^x, \hat{b}_i^y)$ 为中心的候选，具有维度 $(\hat{b}_i^W, \hat{b}_i^H)$ ，对象概率 $\hat{C}_i \in [0, 1]$ 表示一个真实对象，以及一个 K 类概率向量 $\hat{p}_i = (\hat{p}_i^1, \hat{p}_i^2, \dots, \hat{p}_i^K)$ 。这是

通过将输入 x 划分为不同尺度（分辨率）的网格来完成的。每个网格单元产生多个候选边界框，基于锚点并负责定位以单元为中心的对象。最终检测结果 $\hat{\mathcal{O}}(x)$ 通过应用置信度阈值来移除预测置信度低的候选，并通过非极大值抑制（Non-maximum Suppression, NMS）来排除重叠度高的候选。以 YOLOv3^[43] 为例。它将一个大小为 (416×416) 的输入图像划分为 (13×13) , (26×26) 和 (52×52) 网格，其中每个网格单元与三个锚点相关联。因此， $S = 3 \times (13 \times 13 + 26 \times 26 + 52 \times 52) = 10,647$ 个候选边界框在一个给定输入上被预测。那些预测置信度低于 $t_{\text{conf}} = 0.20$ 的候选将立即被丢弃。剩余的将通过具有交并集阈值 $t_{\text{IOU}} = 0.45$ 的 NMS 进一步过滤。YOLOv3 具有维度先验和位置预测的边界框如图2-2所示。




图 2-2 YOLOv3 具有维度先验和位置预测的边界框示意图

深度目标检测是多任务学习的实例，具有三个学习组件，每个组件对应于三个输出结构之一（图2-3），描述一个检测到的对象：（1）目标，（2）边界框，和（3）类别标签。目标得分 $\hat{C}_i \in [0, 1]$ 决定了对象的存在，可以通过最小化二元交叉熵 ℓ_{BCE} 来学习：

$$\mathcal{L}_{\text{obj}}(\tilde{x}; \mathcal{O}, \mathcal{W}) = \sum_{i=1}^S \left[\mathbb{1}_{\hat{C}_i} \ell_{\text{BCE}}(1, \hat{C}_i) + (1 - \mathbb{1}_{\hat{C}_i}) \ell_{\text{BCE}}(0, \hat{C}_i) \right] \quad (2-8)$$

位置 $(\hat{b}_i^x, \hat{b}_i^y)$ 和尺寸 $(\hat{b}_i^W, \hat{b}_i^H)$ 构成一个边界框，通过最小化平方误差 ℓ_{SE} 学习得到：

$$\begin{aligned} \mathcal{L}_{\text{bbox}}(\tilde{x}; \mathcal{O}, \mathcal{W}) = & \sum_{i=1}^S \mathbb{1}_{\hat{C}_i} [\ell_{\text{SE}}(\hat{b}_i^x, \hat{b}_i^x) + \ell_{\text{SE}}(\hat{b}_i^y, \hat{b}_i^y) \\ & + \ell_{\text{SE}}(\sqrt{\hat{b}_i^W}, \sqrt{\hat{b}_i^W}) + \ell_{\text{SE}}(\sqrt{\hat{b}_i^H}, \sqrt{\hat{b}_i^H})] \end{aligned} \quad (2-9)$$




图 2-3 目标检测和图像分类模型的输出结构

最后一部分是 K 类概率向量 $\hat{p}_i = (\hat{p}_i^1, \hat{p}_i^2, \dots, \hat{p}_i^K)$ ，它估计候选的类别标签，通过最小化二元交叉熵来优化：

$$\mathcal{L}_{\text{class}}(\tilde{x}; \mathcal{O}, \mathcal{W}) = \sum_{i=1}^S \sum_{c=1}^K \mathbb{I}_i \ell_{\text{BCE}}(p_i^c, \hat{p}_i^c) \quad (2-10)$$

因此，深度目标检测器可以结合上述损失函数进行优化：

$$\mathcal{L}(\tilde{x}; \mathcal{O}, \mathcal{W}) = \mathcal{L}_{\text{obj}}(\tilde{x}; \mathcal{O}, \mathcal{W}) + \mathcal{L}_{\text{bbox}}(\tilde{x}; \mathcal{O}, \mathcal{W}) + \mathcal{L}_{\text{class}}(\tilde{x}; \mathcal{O}, \mathcal{W}). \quad (2-11)$$

举例来说，FRCNN 的多任务目标损失函数如下：

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{\text{cls}}} \sum_i L_{\text{cls}}(p_i, p_i^*) + \lambda \frac{1}{N_{\text{reg}}} \sum_i p_i^* L_{\text{reg}}(t_i, t_i^*). \quad (2-12)$$

这里， i 是小批量中一个锚点的索引， p_i 是锚点 i 为对象的预测概率。真实标签 p_i^* 如果锚点是正样本则为 1，如果是负样本则为 0。 t_i 是表示预测边界框的 4 个参数化坐标的向量，而 t_i^* 是与正样本锚点相关的真实边界框的坐标。分类损失 L_{cls} 是针对两个类别（对象与非对象）的对数损失。对于回归损失，使用 $L_{\text{reg}}(t_i, t_i^*) = R(t_i - t_i^*)$ ，其中 R 是鲁棒损失函数（平滑 L_1 ）。项 $p_i^* L_{\text{reg}}$ 表示回归损失仅对正样本锚点（ $p_i^* = 1$ ）激活，否则（ $p_i^* = 0$ ）则禁用。 cls 和 reg 层的输出分别由 $\{p_i\}$ 和 $\{t_i\}$ 组成。

一个对抗样本 x' 是通过对发送给受害者检测器的良性输入 x 进行扰动而生成的，目的是欺骗受害者随机（无目标）或故意（有目标）地错误检测。对抗样本的生成过程可以概念化地表述为

$$\min \|x' - x\|_p \quad \text{s.t.} \quad \hat{\mathcal{O}}(x') \neq \hat{\mathcal{O}}(x) \quad (2-13)$$

其中 p 是距离度量，例如 L_0 范数测量被改变的像素的百分比， L_2 范数计算欧几里得距离，或 L_∞ 范数表示任何像素的最大变化。

图2-4给出了对 YOLOv3 检测器进行对抗攻击的示例。给定一个有人持有停车标志的良性图像，上图显示受害者检测器可以高置信度（均为 1.00）准确定位两个对象。在对良性输入图像添加一个小而恶意的扰动后，为这个良性输入 x 生成了一个对抗样本 x' 。虽然 x' 在视觉上与良性输入无法区分，但当将 x' 作为查询输入时，同一目标检测器返回没有对象（即， $\hat{O}(x') = \emptyset$ ），因为这种攻击是为了扰动输入图像，使得每个候选边界框的预测置信度非常低（接近零）。结果，没有候选对象通过置信度阈值（ $t_{\text{conf}} = 0.20$ ）。




图 2-4 对 YOLOv3 检测器的对抗性攻击示例

DAG^[44] 和 RAP^[45] 使用基于迭代梯度的方法禁用两阶段模型（例如 Faster R-CNN^[42]）中区域提议网络的功能。UEA^[46] 提出训练生成对抗网络来产生对抗样本。虽然上述技术揭示了深度目标检测器的对抗性漏洞，但它们侧重于使用 RPN 的两阶段模型。此外，它们的不利影响是随机的，只能欺骗受害者以不可控的行为做出不当行为。

Chow 等人^[47] 提出了一组名为 TOG 的对抗目标梯度攻击，可以使最先进的深度目标检测网络遭受无目标的随机攻击或具有三种特定类型的定向攻击：目标消失、目标伪造和目标误标。

通过固定输入图像 $\tilde{x}$ 并逐步更新模型权重 $\mathcal{W}$ 以实现深度目标检测网络的训练（方程2-4），TOG 通过逆转训练过程进行对抗攻击。固定受害者检测器的模型权重，并迭代更新输入图像 x 以实现由要发起的攻击类型定义的目标，使用以下通用方程：

$$x'_t = \prod_{x, \epsilon} \left[x'_{t-1} - \alpha_{\text{TOG}} \Gamma \left(\frac{\partial \mathcal{L}^*(x'_{t-1}; \mathcal{O}^*, \mathcal{W})}{\partial x'_{t-1}} \right) \right] \quad (2-14)$$

其中 $\Pi_{x, \epsilon}[\cdot]$ 是在以 x 为中心、半径为 ϵ 的 L_p 范数上的超球上的投影，随后进行裁剪以确保像素值的有效性， α_{TOG} 是攻击学习率， Γ 是一个符号函数。通过策略性地操纵对抗损失 $\mathcal{L}^*$ 和辅助目标检测 $\mathcal{O}^*$ ，TOG 不仅支持无目标的随机攻击，使受害者行为失控^[44-46]，还支持三种有目标的特定攻击，欺骗受害者故意误检测。

2.3 对抗样本可解释性理论

探究对抗性样本的形成机制及其可解释性，对于深刻理解深度学习模型的固有缺陷、设计有效防御方案以及建立稳健人工智能体系具有重要的学术意义。Han 研究团队^[56] 对此领域的研究成果进行了系统化分类。研究表明，对抗样本的产生不仅与数据特性相关，更与模型的结构特征存在本质联系。本章将从模型固有属性与数据分布规律两个层面展开深入探讨，揭示其与对抗样本生成之间的作用机理。

2.3.1 模型结构维度分析

从模型架构维度理解对抗样本的研究主要聚焦三个关键阶段：训练前、训练中和训练后。在模型初始化阶段，其固有的线性特征与预置模块（如网络块结构、激活函数等）可能构成对抗脆弱性的潜在诱因。在模型训练阶段，损失函数的选择、优化算法的应用以及训练技巧的实施都会对模型稳健性产生显著影响。在模型部署阶段，现有研究主要从三个维度展开讨论：其一，模型内部存在固有缺陷的理论假设，认为对抗样本的产生具有必然性；其二，模型性能指标（包括原始准确率、受损准确率及转换准确率）可作为鲁棒性评估依据；其三，模型决策边界特征为解释对抗样本提供了重要切入点。

（1）模型固有特性

线性特性假说：Goodfellow 等学者^[53] 开创性地提出，尽管 CNN 包含大量非线性组件，但优化效率需求促使网络呈现准线性特征。这种高维空间的准线性特性使得微小扰动可在输出端产生显著变化。其提出的 FGSM 攻击方法通过代价函数线性化快速生成对抗样本，为线性假说提供了实证支持。Li 团队^[57] 进一步验证了模型参数中的线性系数对扰动放大效应具有促进作用，能够显著提升误导性预测的置信度。**网络架构影响：**相关研究指出，模型架构设计是影响对抗鲁棒性的关键因素，具体体现在组件选择与规模设计两个维度。以残差网络中的跳跃连接为例^[58]，该结构虽能有效保留低级特征并构建深层网络，但 Wu 等学者^[19] 发现其会导致梯度主要通过跳跃连接反向传播，从而增强对抗样本的可迁移性。此外，网络组件的多样性组合也被证实与模型鲁棒性存在关联。**非线性激活机制：**Rahnama 等研究者^[2] 运用 Lyapunov 稳定性理论，将 DNN 各层视为非线性系统进行鲁棒性分析。其理论推导表明，激活函数的选择直接影响模型稳健性，其中 Leaky ReLU 相比传统 ReLU 能构建更具鲁棒性的网络结构。该发

现为对抗训练中的激活函数选择提供了理论指导。

(2) 训练机制分析

现代 CNN 训练流程包含参数初始化、损失计算、梯度更新等核心环节，并辅以多种优化技巧。研究表明，训练过程中的各要素与模型脆弱性存在密切关联。损失函数特性：作为分类任务的标准损失函数，交叉熵损失虽能有效提升模型性能^[58]，但 Nar 等学者^[59]的理论研究表明，在特征分布于仿射子空间的假设下，使用梯度下降优化交叉熵损失可能导致决策边界间隔显著缩小。随着特征空间维度降低，这种间隔压缩效应加剧，从而为对抗样本的生成创造了条件。正则化与归一化：正则化技术虽能提升模型泛化能力，但 Deniz 团队^[60]发现其可能引发局部过拟合现象，进而降低对抗鲁棒性。他们通过实验揭示了模型拟合度与鲁棒性之间的正相关关系，指出对抗样本现象本质上是机器学习中拟合-泛化权衡的体现。批量归一化技术^[61]虽能加速训练并提升清洁准确率，但研究证实其会损害对抗鲁棒性^[62]，该现象在层归一化、组归一化等变体中也普遍存在。

(3) 决策边界特性

决策边界作为输入空间中划分不同类别的超曲面，其几何特性为解释对抗样本提供了重要视角。边界倾斜理论：Tanay 与 Griffin^[63]突破线性假设的局限，提出决策边界沿特定方向倾斜会导致对抗强度无限增大的理论模型，为理解对抗样本的生成机制提供了新的数学框架。边界相似性现象：Tramer 等学者^[64]研究发现，不同模型的决策边界在对抗方向上的距离始终小于数据点到边界的最小距离，这种几何相似性解释了对抗样本的可迁移性。Che 团队^[65]基于此现象开发了集成策略，通过捕捉小批量数据中的可迁移信息，显著提升了对抗样本的迁移成功率。该研究揭示了决策边界相似性在对抗攻击中的重要作用。

2.3.2 数据驱动维度分析

数据作为深度学习模型的训练基础，其内在特性与对抗样本的产生机理存在深刻关联。本节从数据维度、分布规律、属性特征、子空间映射及网络特征五个维度系统剖析数据要素对抗样本的影响机制。

(1) 高维数据特性

数据的维度效应在对抗样本研究中占据重要地位。Simon-Gabriel 团队^[66]通过数学建模揭示了对抗脆弱性与输入维度的正相关规律：损失函数梯度范数随维度 d 的平方根增长，该现象在模型初始化与对抗训练后持续存在。Gorban 等学者^[67]基于绝对连续性假设的缺失，从理论上证明当数据维度足够大时，对抗样本的存在具有必然性。值得注意的是，通过正则化技术可有效缓解维度效应对模型鲁棒性的负面影响。

(2) 分布规律解析

数据分布的统计特性与模型脆弱性存在双重关联机制：分布固有缺陷：Shafahi 研究组^[68]论证了多数实际数据分布均存在对抗样本的必然性。Dohmatob 等^[69]构建的

Wasserstein-2 空间传输框架表明，当数据满足 Talagrand 不等式时，任何分类器都无法抵御略强于自然噪声的对抗扰动，揭示了广泛存在的分布脆弱性。分布偏移理论：Grosse 等人^[70] 提出对抗样本源于实际数据分布与模型学习分布间的统计差异。有限训练样本导致模型只能近似真实分布，而对抗样本恰位于未被学习的真实分布区域，形成具有统计显著性的对抗分布。

（3）数据集属性影响

Shamir 团队^[71] 指出类别数量与特征维度的不平衡（如高维像素空间下的有限类别）显著削弱模型鲁棒性。Li 等研究者^[72] 发现过载的类别划分导致决策区域交错，为对抗攻击创造结构条件。Wang 研究组^[73] 建立的类偏差-方差理论框架表明，在有限训练样本条件下，即便采用鲁棒算法也难以避免模型脆弱性，而充足样本量可有效提升对抗鲁棒性。

（4）子空间映射分析

针对高维数据的复杂性，研究通过子空间投影揭示对抗样本本质：流形几何特性：Szegedy 等^[1] 早期研究指出对抗样本位于数据流形的低概率密集区域，难以通过常规采样发现。Stutz 团队^[74] 将对抗样本分为两类：正交偏离流形的常规对抗样本（扰动方向与流形垂直）及位于流形上的泛化误差样本，后者可作为增强模型泛化能力的有效训练样本。

（5）深度特征解构

中间层特征分析为理解对抗样本提供新视角。特征空间异常：Mao 等^[75] 通过 t-SNE 可视化发现对抗样本在特征空间中显著偏离原始类别簇。Xie 研究组^[76] 揭示对抗扰动引发特征图噪声激活，导致语义无关区域异常响应，从而误导模型预测。特征归因方法：Yang 等^[77] 应用 Leave-One-Out 方法量化特征重要性差异，发现对抗样本存在异常特征贡献模式。经典可解释方法 LIME^[78] 和 SHAP^[79] 成功建立对抗样本解释与模型决策机制间的关联。特征类型学：研究将深度特征划分为类内/类间特征、局部/全局特征、鲁棒/非鲁棒特征等类别。Agarwal 等^[80] 通过优化类内紧凑性和类间可分性提升鲁棒性。Mustafa 团队^[81] 发现深层特征空间的类间紧密度是微小扰动改变预测的根本原因。Liu 等^[82] 提出的鲁棒特征理论指出，充分利用与标签强相关的鲁棒特征，抑制弱相关非鲁棒特征，是构建稳健模型的关键路径。

2.4 本章小结

3 基于快速平坦近邻采样的图像分类可迁移对抗攻击

3.1 问题与挑战

现有的针对分类神经网络生成对抗样本的攻击方法^[3-5]在白盒模型场景下表现良好，但在对黑盒模型进行迁移攻击时成功率仍有待提高。现有的方法将对抗样本迁移能力差的原因归结于生成的对抗样本容易陷入局部极大值或者对于白盒替代模型的过拟合，导致了很难进行跨模型的迁移攻击。为了解决这个问题，研究人员从很多角度提出了不同的方法。基于梯度优化的攻击方法通常尝试提出先进的梯度计算更新方法提高对抗样本迁移性。基于输入变换的方法从数据的角度对输入图像应用不同的各种变换来提高黑盒攻击成功率。这些方法主要是从优化和泛化的角度提出的，将对抗样本在白盒模型上生成的过程视为标准的神经网络训练过程，将对抗可迁移性等价于模型泛化性，虽然这些方法可以提高对抗性示例的可迁移性，但基于迁移的黑盒攻击仍落后于白盒攻击。

在基于梯度优化的方法中，损失的平坦极小值被重点关注用于研究对抗样本的生成和迁移性，利用平坦局部极小值进行迁移攻击的方法表现出了强大的黑盒攻击能力。现存方法的问题在于：

(1) 对抗样本到达平坦极小值付出的巨大时间计算成本，在同一迭代中由于多次梯度导致对抗样本容易对白盒模型过拟合；

(2) 为了稳定梯度更新方向，在对抗样本邻域进行随机采样时不可避免产生方差，从而降低了对抗样本迁移能力。

3.2 算法设计

3.2.1 算法概述

为了解决现有的基于梯度优化的算法的问题，本章提出一种基于快速平坦近邻采样的可迁移对抗样本生成算法 FFSA (Fast Flat Neighborhood Sampling Attack)，使用近似优化对目标函数的梯度更新进行简化，同时为了获得更稳定的梯度方向，对样本子空间范围进行随机采样并获取平均梯度，从而减少迭代过程中随机采样造成的方差，进而在提高计算效率的同时大大增强对抗样本的黑盒迁移攻击能力。算法流程如图3-1所示。

3.2.2 平坦局部极小值

尽管先前的研究在白盒攻击中表现良好，但从 $\mathcal{M}^S$ 生成的对抗样本在 $\mathcal{M}^T$ 上的对抗迁移性较差。先前的工作将对抗样本迁移性差问题归因于对 $\mathcal{M}^S$ 的对抗攻击过拟合。





图 3-1 FFSA 算法流程

如图3-3（b）所示，当 x^{pgd} 位于尖锐的局部最小值时，它不稳定，对 $\mathcal{M}^S$ 的变化敏感。当模型参数发生变化时， x^{pgd} 可能导致对 $\mathcal{M}^{S'}$ 的高攻击损失并导致攻击失败。

损失景观（loss landscape）是深度学习中对损失函数几何形态的直观描述，它将高维参数空间中的损失值映射为一个多维曲面。对于具有 n 个参数的神经网络，损失函数 L 将每个参数组合映射为一个实数，损失景观可视为所有 $(param, L(param))$ 的集合，形成一个 $n + 1$ 维的超曲面。通过损失景观的几何特性（如鞍点、平坦区域），可分析优化算法（如 SGD、Adam）的收敛行为。例如，跳过连接（Skip Connections）^[19] 能产生更平缓的景观，从而加速收敛。



为了减轻对 $\mathcal{M}^S$ 的过拟合，Qin 等人^[83] 主张找到位于平坦局部区域的 x^{adv} 。这意味着不仅要求 x^{adv} 本身具有低损失值，还要求 x^{adv} 附近的点具有类似的低损失值。为




图 3-3 损失函数平坦局部极小值示意图

此，在对抗样本 x^{adv} 周围的局部邻域区域内最小化最大损失值。通过扰动更新 x^{adv} 来最大化攻击损失来实现最大损失，称为反向对抗扰动（Reverse Adversarial Perturbation, RAP）。通过将 RAP 插入公式2-4，旨在解决以下问题：

$$\min_{x^{adv} \in \mathcal{B}_\epsilon(x)} \mathcal{L}(\mathcal{M}^s(\mathcal{G}(x^{adv} + n^{rap}); \theta), y_t) \quad (3-1)$$

其中

$$n^{rap} = \arg \max_{\|n^{rap}\|_\infty \leq \epsilon_n} \mathcal{L}(\mathcal{M}^s(x^{adv} + n^{rap}; \theta), y_t) \quad (3-2)$$

n^{rap} 表示 RAP， ϵ_n 定义其搜索区域。上述公式3-1和3-2 对应于定向攻击，通过分别用 $-\mathcal{L}$ 和 y 替换损失函数 $\mathcal{L}$ 和 y_t ，可以获得相应的无目标攻击优化公式。这是一个最小-最大（min-max）两级优化问题^[84]，可以通过迭代优化内部最大化和外部最小化问题来解决。具体来说，在每次迭代中，给定 x^{adv} ，关于 n^{rap} 的内部最大化通过投影梯度上升算法解决：

$$n^{rap} \leftarrow n^{rap} + \alpha_n \cdot \text{sign}(\nabla_{n^{rap}} \mathcal{L}(\mathcal{M}^s(x^{adv} + n^{rap}; \theta), y_t)) \quad (3-3)$$

上述更新通过 T 步进行， $\alpha_n = \frac{\epsilon_n}{T}$ 。然后，给定 n^{rap} ，关于 x^{adv} 的外部最小化可以通过任何现有的算法解决公式2-4。例如，可以通过以下单步投影梯度下降进行更新：

$$x^{adv} \leftarrow \text{Clip}_{\mathcal{B}_\epsilon(x)} [x^{adv} - \alpha \cdot \text{sign}(\nabla_{x^{adv}} \mathcal{L}(\mathcal{M}^s(\mathcal{G}(x^{adv} + n^{rap}); \theta), y_t))] \quad (3-4)$$

其中 $\text{Clip}_{\mathcal{B}_\epsilon(x)}(\cdot)$ 将输入限制到邻域区域 $\mathcal{B}_\epsilon(x)$ 内。整体优化过程在算法1中总结。此外，由于关于 x^{adv} 的优化可以通过任何现成的算法实现公式2-4，RAP 的一个显著优势是它可以自然地与它们中的任何一个结合，例如输入转换方法^[13-16]。

3.2.3 梯度范数与平坦局部极大值

在 Hochreiter 等人^[85] 指出良好泛化模型可能具有平坦极小值之后，极小值的平坦性与模型泛化之间的联系已从经验性和理论性的角度进行了研究^[86-89]。Li 等人^[90] 观

算法 3-1 反向对抗扰动 (RAP) 算法

Input: 替代模型 $\mathcal{M}^s$, 良性数据 (x, y) , 目标标签 y_t , 损失函数 $\mathcal{L}$, 变换 $\mathcal{G}$, 全局迭代次数 K , RAP 的延迟开始迭代次数 K_{LS}

Output: 对抗样本 x^{adv}

```

1 Initiative:  $x^{adv} \leftarrow x$ 
2 for  $k = 1, \dots, K$  do
3   if  $k \geq K_{LS}$  then
4     初始化  $n^{rap} \leftarrow 0$ 
5     for  $t = 1, \dots, T$  do
6        $n^{rap} \leftarrow n^{rap} + \alpha_n \cdot \text{sign}(\nabla_{n^{rap}} \mathcal{L}(\mathcal{M}^s(x^{adv} + n^{rap}; \theta), y_t))$ 
7     end
8   end
9    $x^{adv} \leftarrow \text{Clip}_{\mathcal{B}_\epsilon(x)} [x^{adv} - \alpha \cdot \text{sign}(\nabla_{x^{adv}} \mathcal{L}(\mathcal{M}^s(\mathcal{G}(x^{adv} + n^{rap}); \theta), y_t))]$ 
10 end

```

察到跳跃连接促进平坦极小值, 这有助于解释为什么跳跃连接对于训练极深网络是必要的。同样, Santurkar 等人^[91]发现 BatchNorm 在训练过程中显著平滑了优化景观。锐度感知最小化 (Sharpness-Aware Minimization, SAM)^[88]通过同时最小化损失值和锐度来改善模型泛化, 它寻找具有均匀低损失值的邻域中的参数。Jiang 等人^[92]研究了 40 种复杂性度量, 并表明基于锐度的度量与泛化的相关性最高。Zhao 等人^[89]证明了添加损失函数的梯度范数可以帮助优化器找到平坦的局部极小值。

Ge 等人^[93]提出了惩罚梯度范数 (Penalize Gradient Norm, PGN) 通过向原始损失函数引入了惩罚梯度正则化范数 (L_2 范数), 这有助于对抗样本实现平坦的最大值。

假设 1: 给定任何具有小半径 $\zeta > 0$ 的局部区域, 针对相同输入 x 的两个对抗样本 x_1^{adv} 和 x_2^{adv} , 如果 $\max_{x' \in \mathcal{B}_\zeta(x_1^{adv})} \|\nabla_{x'} J(x', y; \theta)\|_2 < \max_{x' \in \mathcal{B}_\zeta(x_2^{adv})} \|\nabla_{x'} J(x', y; \theta)\|_2$, 那么 x_1^{adv} 很可能比 x_2^{adv} 在各种模型中具有更好的迁移攻击能力。

SAM^[88]表明平坦的局部最小值是整个邻域具有低损失和低曲率。Zhao 等人^[89]也证明如果损失函数具有较小的梯度值, 这将表明损失函数景观更平坦。PGN 采用邻域内的最大梯度来评估局部区域的平坦度。根据假设 1, 引入一个正则化项, 该正则化项最小化输入的 ζ 球内的最大梯度, 那么方程 2-6 可以近似于以下优化问题:

$$\max_{x^{adv} \in \mathcal{B}_\epsilon(x)} \mathcal{L}(x^{adv}, y; \theta) \approx J(x', y; \theta) - \lambda \cdot \|\nabla_{x'} J(x', y; \theta)\|_2, \quad \text{s.t. } x' \in \mathcal{B}_\zeta(x^{adv}) \quad (3-5)$$

其中 $\lambda \geq 0$ 是惩罚系数。在优化过程中, 对最大梯度的 L_2 范数进行惩罚, 以感知那些无法通过使用平均梯度识别的更尖锐的区域。通过优化问题 3-5, 可以发现在其邻域内数据点梯度较小的对抗样本应该位于平坦的局部区域。然而, 由于邻域内数据点的数量级过大, 在 ζ 球内计算最大梯度是不切实际的。因此, 可以通过在每次迭代中随机采

样 $x' \in \mathcal{B}_\zeta(x^{adv})$ 来近似优化方程3-5。

算法 3-2 惩罚梯度范数攻击方法 (PGN)

Input: 一张带有真实标签 y 的干净图像 x , 以及具有参数 θ 的损失函数 J

Output: 对抗样本 x^{adv}

- 1 参数: 扰动的大小 ϵ ; 最大迭代次数 T ; 衰减因子 μ ; 平衡系数 δ ; 在 ζ 球内随机采样的上界 (即 ζ); 随机采样样本的数量 N
- 2 $g_0 = 0, x_0^{adv} = x, \alpha = \epsilon/T$
- 3 **for** $t = 0, 1, \dots, T - 1$ **do**
- 4 设置 $\bar{g} = 0$
- 5 **for** $i = 0, 1, \dots, N - 1$ **do**
- 6 随机采样一个样本 $x' \in \mathcal{B}_\zeta(x_t^{adv})$
- 7 计算样本 x' 处的梯度 $g' = \nabla_{x'} J(x', y; \theta)$
- 8 通过 $x^* = x' - \alpha \cdot \frac{g'}{\|g'\|_1}$ 计算预测点
- 9 计算预测点的梯度 $g^* = \nabla_{x^*} J(x^*, y; \theta)$
- 10 累积更新梯度 $\bar{g} = \bar{g} + \frac{1}{N} \cdot [(1 - \delta) \cdot g' + \delta \cdot g^*]$
- 11 **end**
- 12 $g_{t+1} = \mu \cdot g_t + \frac{\bar{g}}{\|\bar{g}\|_1}$
- 13 通过 $x_{t+1}^{adv} = \Pi_{\mathcal{B}_\epsilon(x)} [x_t^{adv} + \alpha \cdot \text{sign}(g_{t+1})]$ 更新 x_{t+1}^{adv}
- 14 **end**
- 15 **return** $x^{adv} = x_T^{adv}$.

在实践中, 直接优化方程3-5计算量过大, 因为需要计算 Hessian 矩阵。Hessian 矩阵是一种描述多元函数二阶导数信息的核心工具, 对于一个 n 维函数 $\{(x_1, x_2, \dots, x_n)\}$, 其定义为由二阶偏导数构成的对称方阵, 对于损失函数 J 来说 $\nabla_x^2 J(x, y; \theta)$ 等价于 Hessian 矩阵。可以使用有限差分法 (Finite Difference Method) 来近似二阶 Hessian 矩阵, 以加速攻击过程。具体来说, 采用局部泰勒展开来近似 Hessian 矩阵与梯度向量之间的操作结果。根据泰勒展开, 得到:

$$\nabla_x J(x + \Delta x, y; \theta) = \nabla_x J(x, y; \theta) + \nabla_x^2 J(x, y; \theta) \Delta x + O(\|\Delta x\|^2), \quad (3-6)$$

其中 $\Delta x = \alpha \cdot v$, α 是一个小步长, v 是一个归一化的梯度方向向量。这里, 由于 v 可以是任意单位向量, 记 $v = -\frac{\nabla_x J(x, y; \theta)}{\|\nabla_x J(x, y; \theta)\|_2}$ 。因此, Hessian-向量积可以通过一阶梯度近似如下:

$$\nabla_x^2 J(x, y; \theta) \cdot v \approx \frac{\nabla_x J(x + \alpha \cdot v, y; \theta) - \nabla_x J(x, y; \theta)}{\alpha}. \quad (3-7)$$

基于梯度的攻击在实际优化过程中需要计算目标函数的梯度, 因此当前损失函数3-5的梯度可以表示如下:

$$\begin{aligned}\nabla_{x^{adv}} \mathcal{L}(x^{adv}, y; \theta) &\approx \nabla_{x'} J(x', y; \theta) - \lambda \cdot \nabla_{x'} (\|\nabla_{x'} J(x', y; \theta)\|_2) \\ &\approx \nabla_{x'} J(x', y; \theta) - \lambda \cdot \nabla_{x'}^2 J(x', y; \theta) \cdot \frac{\nabla_{x'} J(x', y; \theta)}{\|\nabla_{x'} J(x', y; \theta)\|_2}.\end{aligned}\quad (3-8)$$

根据方程3-8和3-7，损失函数 $\mathcal{L}(\cdot)$ 的梯度可以表示为：

$$\begin{aligned}\nabla_{x^{adv}} \mathcal{L}(x^{adv}, y; \theta) &\approx \nabla_{x'} J(x', y; \theta) - \lambda \cdot \nabla_{x'}^2 J(x', y; \theta) \cdot \frac{\nabla_{x'} J(x', y; \theta)}{\|\nabla_{x'} J(x', y; \theta)\|_2} \\ &\approx \nabla_{x'} J(x', y; \theta) + \lambda \cdot \frac{\nabla_{x'} J(x' + \alpha \cdot v, y; \theta) - \nabla_{x'} J(x', y; \theta)}{\alpha} \\ &= \left(1 - \frac{\lambda}{\alpha}\right) \cdot \nabla_{x'} J(x', y; \theta) + \frac{\lambda}{\alpha} \cdot \nabla_{x'} J(x' + \alpha \cdot v, y; \theta)\end{aligned}\quad (3-9)$$

引入一个平衡系数 δ 并记作 $\delta = \frac{\lambda}{\alpha}$ 。因此，在第 t 次迭代时，目标函数3-5的梯度可以近似为：

$$\nabla_{x_t^{adv}} \mathcal{L}(x_t^{adv}, y; \theta) \approx (1 - \delta) \cdot \nabla_{x'_t} J(x'_t, y; \theta) + \delta \cdot \nabla_{x'_t} J(x'_t + \alpha \cdot v, y; \theta) \quad (3-10)$$

其中，根据公式3-5，由于需要最大化 $\mathcal{L}(x^{adv}, y; \theta)$ ，同时在 $x' \in \mathcal{B}_\zeta(x^{adv})$ 条件下最小化 $\nabla_{x'} J(x', y; \theta)$ ，所以在对随机采样点 ζ 半径内的预测点 x^* 进行更新时采取梯度下降法，在对第 t 次迭代的对抗样本 x' 进行更新时采取梯度上升法：

$$x^* = x' - \alpha \cdot \frac{\bar{g}}{\|\bar{g}\|_1} \quad (3-11)$$

其中， $\alpha = \epsilon/T$ ， $\bar{g}$ 为一个迭代内所有采样的平均梯度，并通过以下方程更新平均梯度：

$$\bar{g} = \bar{g} + \frac{1}{N} \cdot [(1 - \delta) \cdot g' + \delta \cdot g^*] \quad (3-12)$$

因此，PGN 通过插值两个相邻梯度来近似方程3-5的梯度，然而，由于随机抽样过程，这种方法引入了方差。为了解决这个问题，PGN 随机采样多个样本点并平均这些样本点的梯度以获得更稳定的梯度。这种平均有助于减少近似和随机性引入的误差，从而产生更准确的梯度估计。PGN 攻击的流程如算法2所示。

3.2.4 快速平坦近邻采样对抗样本攻击

然而，这种插值相邻梯度近似方程3-5的梯度的方法存在一个严重的被忽视的问题，由于当前采样点的梯度被直接用来寻找预测点，在梯度下降的过程中容易陷入局部尖锐点，从而导致难以寻找到梯度方差较小的预测点并且对白盒替代模型过拟合。

为了解决这个问题，本文提出一种新的可迁移对抗样本生成算法：快速平坦近邻采样对抗攻击（Fast Flat Neighborhood Sampling Adversarial Attack, FFSA）。这种攻击方法相比现存的黑盒迁移攻击具有更高的可迁移性和更少的计算复杂度。生成的对抗样本如图所示。主要创新点如下：

- (1) 简化了每个迭代中随机采样平均梯度的计算方式，每次随机采样只计算一次



图 3-4 使用 FFSA 生成的对抗样本示意图

梯度信息，不仅提高了对抗样本迁移能力，时间复杂度也从 $\mathcal{O}(2N)$ 减少到 $\mathcal{O}(N)$ 。

(2) 对每次随机采样点周围子区域的上界进行随机调整，避免了固定上界造成的邻域信息损失。

简化的有约束预测点搜寻方式，即采用上一次迭代的相应采样点的梯度 $g'_{t-1,i}$ 来寻找当前迭代随机采样点 $x'_{t,i}$ ：

$$g'_{t,i} = \nabla_{x'_{t,i}} J(x'_{t,i}, y; \theta) \approx g'_{t-1,i} \quad (3-13)$$

寻找预测点 $x'_{t,i}$ ，并保证 $x'_{t,i}$ 被约束到 $x_{t,i}$ 邻域的 ρ 球之内：

$$x'_{t,i} = \prod_{B_\rho(x_{t,i})} [x_{t,i} - \rho \cdot \text{sign}(g'_{t-1,i})] \quad (3-14)$$

这种方法只需要在每次采样时计算一次梯度，将每次迭代的时间复杂度从 $\mathcal{O}(2N)$ 减少到 $\mathcal{O}(N)$ ，节约了一半的计算时间，同时通过预测点邻域限制减少了预测点的空间偏移，缓解了对抗样本的过拟合现象，使得能够更有效地寻找到平坦局部极大值并实现更好的对抗可迁移性。保证了子区域内目标函数值最小的点最终将具有相对较高的目标值，从而确保更有效和多样化的采样。

本文将这种简化的平坦极大值采样方式称为，算法的流程如下：

- (1) 输入一张干净图片 x ，以及具有参数 θ 的损失函数 J 。
- (2) 进行 T 次迭代，每次随机迭代开始时设置平均梯度 $\bar{g} = 0$ 。

(3) 每次迭代进行 N 次随机采样。

(4) 每次随机采样一个样本 $x_{t,i} \in \mathcal{B}_\zeta(x_t^{adv})$, 其中 $x_{t,i}$ 表示第 t 次迭代的第 i 次随机采样的样本, 并将其限制在当前对抗样本 x_t^{adv} 的 ζ 球内。

(5) 在区间 $[\rho_{low}, \rho_{up}]$ 内随机采样一个子区域上界 ρ , 通过公式3-14计算预测点 $x'_{t,i}$, 利用前一迭代预测点的梯度 $g'_{t-1,i}$ 获得预测点, 范围限制在 $x_{t,i}$ 的 ρ 球内。

(6) 计算 $x'_{t,i}$ 点的梯度 $g'_{t,i} = \nabla_{x'_{t,i}} J(x'_{t,i}, y; \theta)$ 。

(7) 累积更新平均梯度 $\bar{g} = \bar{g} + \frac{1}{N} \cdot g'_{t,i}$ 。

(8) N 次采样结束后利用动量法更新梯度 $g_{t+1} = \mu \cdot g_t + \frac{\bar{g}}{\|\bar{g}\|_1}$ 。

(9) 通过梯度上升更新对抗样本 $x_{t+1}^{adv} = \Pi_{\mathcal{B}_\epsilon(x)} [x_t^{adv} + \alpha \cdot \text{sign}(g_{t+1})]$, 步长为 α , 限制在干净样本的 ϵ 球内。

(10) 全部迭代结束后得到对抗样本 $x^{adv} = x_T^{adv}$ 。

FFSA 算法的伪代码如3-3所示。

算法 3-3 快速平坦近邻采样对抗攻击算法 (FFSA)

Input: 一张带有真实标签 y 的干净图像 x , 以及具有参数 θ 的损失函数 J

1 参数: 扰动幅度 ϵ ; 最大迭代次数 T ; 衰减因子 μ ; 随机采样的上界 ζ ; 样本点周围子区域的上界 $\rho \in [\rho_{low}, \rho_{up}]$; 随机采样样本的数量 N

2 $g_0 = 0, x_0^{adv} = x, g'_{-1,i} = 0, \alpha = \epsilon/T$

3 **for** $t = 0, 1, \dots, T-1$ **do**

4 设置 $\bar{g} = 0$

5 **for** $i = 0, 1, \dots, N-1$ **do**

6 随机采样一个样本 $x_{t,i} \in \mathcal{B}_\zeta(x_t^{adv})$

7 在区间 $[\rho_{low}, \rho_{up}]$ 内随机采样一个子区域上界 ρ

8 计算 $x'_{t,i} \in B_\rho(x_{t,i})$ 通过 $x'_{t,i} = \Pi_{B_\rho(x_{t,i})}[x_{t,i} - \rho \cdot \text{sign}(g'_{t-1,i})]$

9 计算 $x'_{t,i}$ 点的梯度 $g'_{t,i} = \nabla_{x'_{t,i}} J(x'_{t,i}, y; \theta)$

10 累积更新平均梯度 $\bar{g} = \bar{g} + \frac{1}{N} \cdot g'_{t,i}$

11 **end**

12 $g_{t+1} = \mu \cdot g_t + \frac{\bar{g}}{\|\bar{g}\|_1}$

13 通过 $x_{t+1}^{adv} = \Pi_{\mathcal{B}_\epsilon(x)} [x_t^{adv} + \alpha \cdot \text{sign}(g_{t+1})]$ 更新 x_{t+1}^{adv}

14 **end**

15 **return** $x^{adv} = x_T^{adv}$

Output: 对抗样本 x^{adv}

3.2.5 对抗样本损失曲面可视化

鉴于对抗样本 x^{adv} 通常具有大量维度, 对所有维度的损失函数进行可视化变得不可行。为此, 从与 x^{adv} 相同维度的高斯分布中随机选择两个方向, 记为 r_1 和 r_2 。接下

来, 通过改变 r_1 和 r_2 的大小来计算损失的变化, 分别表示为 k_1 和 k_2 , 这两个因子应用于 r_1 和 r_2 , 从而能够使用二维图来可视化损失函数。这种方法提供了损失函数的一个切片, 从而能够分析其行为并理解沿不同方向的扰动影响。

在 NIPS2017 对抗竞赛数据集中随机选择两个可以被 FFSA 攻击成功但是不能被其他基线方法成功攻击的图像。这些对抗样本是通过在 Inc-v3 上使用各种基于梯度的攻击方法生成的。如图3-5所示, 可以观察到本章的方法生成的对抗样本在视觉上与其他攻击相似。因此, 本章的方法展示了引导对抗样本朝向更大更平滑平坦区域的能力。这一观察结果证明了 FFSA 方法在生成位于平坦区域内的对抗样本方面的有效性, 从而揭示了平坦局部最大值在生成可迁移对抗样本中的潜在作用。

为了验证 FFSA 方法能够帮助对抗样本找到平坦的最大值区域, 在替代模型 (即 Inc-v3) 上比较了不同攻击方法生成的对抗样本的损失曲面图。随机采样三张图片, 每个小型二维图对应一个对抗样本, 该对抗样本位于数据集中, 并比较图3-6中的损失曲面, 每列表示一张图像的可视化结果。从比较中, 可以很容易的观察到 FFSA 方法可以帮助对抗样本获得比 PGN 和其他基线方法更平坦的最大值区域。本章方法生成的对抗样本位于更大且更平滑的平坦局部最大值区域。这证实了所提出方法可以生成位于平坦最大值区域的对抗样本。由于对抗样本位于更平坦的局部最大值区域, FFSA 比现有攻击方法具有更好的黑盒可迁移性。




图 3-5 原始图像与对抗图像损失表面可视化对比




图 3-6 损失表面可视化

3.3 实验与结果分析

3.3.1 对比算法

关于数据集信息，本章选用了—个公开的广泛使用用来进行对抗样本评估的数据集即 NIPS2017 对抗挑战赛数据集，NIPS2017 对抗挑战赛数据集与 ImageNet 数据集兼容，在以往的研究工作中被广泛使用，同时数据集中的数据都没在公开的数据集中使用过，保证了模型训练过程中从未见过这些图片，如图3-7所示。包含 1000 张尺寸为 $299 \times 299 \times 3$ 图像，以及真实标签。




图 3-7 NIPS2017 对抗挑战赛数据集

选取五个先进的基于梯度的迭代对抗攻击方法作为基线，包括 VMI-FGSM (VMI)、VNI-FGSM (VNI)、EMI-FGSM (EMI)、RAP、PGN。除此之外，还将所提出的攻击方法与各种输入变换相结合，如 DIM、TIM、SIM、Admix 和 SSM，以验证 FFSA 的通用性。

为了验证 FFSA 方法的有效性，本章在正常训练的图像分类模型和经过了对抗训练的鲁棒模型上对其进行评估。对于正常训练的模型，采用 6 种广泛使用的 CNN 和 4 种基于 Transformer 的神经网络。其中 Resnet-18、Inception-v3、VGG16 这三种 CNN 模型和 ViT 模型分别作为白盒替代模型。对于黑盒目标模型的选择，CNN 包括 ResNet-18 (Res-18)、ResNet-101 (Res-101)、Inception-v3 (Inc-v3)、Inception-v4 (Inc-v4)、VGG16 和 VGG19。除了上述 CNN 之外，还使用了更多样的模型架构，比如基于 Transformer 的网络，包括 ViT-Base/16 (ViT-B/16)、PiT-B、Visformer-S (Vis-S) 和 Swin-Transformer/16 (Swin)。对于鲁棒模型，使用了那些具有主动防御的模型，例如对抗性训练和随机平滑。具体来说，对于鲁棒模型，使用了 $\text{Inc-v3}_{\text{ens3}}$ 、 $\text{Inc-v4}_{\text{ens4}}$ 和 $\text{IncRes-v2}_{\text{ens}}$ 。

3.3.2 实验设置

本章实验环境包括两个方面：硬件和软件。硬件配置方面，CPU 使用了 Intel(R) Xeon(R) Gold 6426Y 处理器，最大频率为 4.1 GHz；总内存为 376G，硬盘空间为 30TB。包括 8 张高性能人工智能 NVIDIA L40S GPU，每张 GPU 包括 48GB 显存空间，单精度浮点运算（FP32）速度为 91.61 TFLOPS，每次实验只使用其中一张 GPU，通过多任务并行有效利用 GPU 资源。软件配置方面，操作系统使用了基于 Linux 的发行版系统 Ubuntu 22.04.4 LTS；采用了 Python 语言作为算法实现编程语言，依赖 mamba 库进行 Python 环境配置，主要利用了 Pytorch 人工智能框架和多种与机器学习相关的依赖库，具体软件环境依赖见表3-1和表3-2。

表 3-1 硬件配置信息表

名称	配置
操作系统	Ubuntu 22.04.4 LTS
CPU	Intel(R) Xeon(R) Gold 6426Y
GPU	NVIDIA L40S GPU $\times$ 8
内存	376G
硬盘	30TB

表 3-2 软件依赖信息表

主要依赖库名称	版本号
Python	3.10.16
Pytorch	1.12.1+cu113
torchvision	0.13.1+cu113
timm	1.0.15
numpy	1.25.2
mmdet	2.28.2
mmdcv-full	1.7.1
pretrainedmodels	0.7.4

本章遵循先前基于梯度的攻击工作中的攻击设置，最大扰动为 $\epsilon = 16/255$ ，迭代次数 $T = 10$ ，步长 $\alpha = \epsilon/T$ ，以及衰减因子 $\mu = 1.0$ 用于 MI。对于基于样本的方法，将采样的样本数量 N 设置为 20。具体来说，对于 VMI 和 VNI，将邻域大小的上限 β 设置为 $1.5 \times \epsilon$ ；对于 EMI，采样间隔界限 $\eta = 7$ ，并采用自适应线性采样。对于 RAP，步长 $\alpha = 2/255$ ，迭代次数 $K = 400$ ，内部迭代次数 $T = 10$ ，延迟启动 $K_{LS} = 100$ 。对于 PGN，将 ξ 的上限设置为 $3.0 \times \epsilon$ ，平衡系数 $\delta = 0.5$ 。对于本章提出的 FFSA，邻域随机采样的上界 $\zeta = 2.5 \times \epsilon$ ，子区域的上界 ρ 的取值范围限制在 $[\rho_{low} = \epsilon/10, \rho_{up} = \epsilon/5]$ 内。

3.3.3 单模型迁移攻击实验

在单一模型设置下进行了一系列基于梯度的攻击，并测试了攻击成功率，这表明当使用对抗样本作为输入时目标模型的误分类率。对抗样本分别在四种不同的模型上生成：Res-18、Inc-v3、VGG16 和 ViT。表3-3和3-4中展示了不同的攻击对于 CNN 模型的攻击成功率。表3-5和3-6展示了基于 Transformer 的模型在不同攻击方法下的攻击成功率。表3-7和3-8展示了不同的鲁棒模型在不同攻击方法下的攻击成功率。

表 3-3 CNN 模型在不同攻击方法下的攻击成功率 (a)

模型	攻击	Res-18	Res-101	Inc-v3	Inc-v4	VGG16	VGG19	平均值
Res-18	VMI	100.0	63.0	67.2	63.8	88.7	87.7	78.4
	VNI	100.0	62.3	65.6	64.0	89.7	87.3	78.2
	EMI	100.0	58.1	61.2	58.8	90.0	88.7	76.1
	RAP	100.0	60.0	59.3	59.6	92.1	88.8	76.6
	PGN	100.0	70.1	78.8	73.3	94.6	93.7	85.1
	FFSA	100.0	81.1	84.6	82.9	97.8	96.1	90.4
Inc-v3	VMI	66.4	56.0	100.0	73.2	67.9	70.2	72.3
	VNI	67.5	54.5	100.0	73.0	69.9	70.3	72.5
	EMI	76.8	57.7	100.0	79.4	77.5	77.8	78.2
	RAP	83.3	62.1	99.9	85.0	86.4	85.5	83.7
	PGN	85.6	75.2	99.8	91.8	85.7	84.8	87.2
	FFSA	88.1	81.4	99.6	92.4	89.4	88.6	89.9

表 3-4 CNN 模型在不同攻击方法下的攻击成功率 (b)

模型	攻击	Res-18	Res-101	Inc-v3	Inc-v4	VGG16	VGG19	平均值
VGG16	VMI	82.9	51.0	58.5	65.9	100.0	98.2	76.1
	VNI	83.4	49.9	58.9	65.2	100.0	99.0	76.1
	EMI	84.2	42.2	52.7	60.6	100.0	98.8	73.1
	RAP	82.3	45.6	49.2	58.2	99.9	98.3	72.3
	PGN	92.7	57.7	74.1	73.9	100.0	99.6	83.0
	FFSA	95.8	70.1	81.6	83.6	100.0	99.5	88.4
ViT	VMI	59.4	47.2	51.8	52.7	63.7	62.7	56.3
	VNI	60.9	44.9	52.4	50.2	63.0	62.1	55.6
	EMI	68.6	54.9	60.7	57.7	70.2	69.1	63.5
	RAP	73.5	52.1	63.6	58.4	77.4	73.3	66.4
	PGN	76.1	69.6	72.7	68.8	75.2	75.8	73.0
	FFSA	75.3	69.1	71.7	70.0	74.2	73.9	72.4

从结果中观察到 FFSA 方法不仅在白盒模型上保持了高攻击成功率，而且显著提

高了黑盒模型上的攻击成功率。例如，在 Res-18 上生成对抗样本时，VMI-FGSM、VNI-FGSM、EMI-FGSM、RAP、PGN 分别在 Inc-v3 上实现了 67.2%、65.6%、61.2%、59.3% 和 78.8% 的攻击成功率。相比之下，FFSA 方法实现了 84.6% 的攻击成功率，超过了 PGN（最佳基线）5.8%。如果比较对于基于 Transformer 的模型比如 ViT、PiT、Vis、Swin 模型，使用 FFSA 在 Res-18 模型上生成的对抗样本分别实现了 42.7%、54.6%、70.0% 和 75.7% 的攻击成功率，平均值达到了 60.8%，均大幅超越 PGN 方法。此外，当对鲁棒模型进行攻击时，FFSA 攻击方法优于其他基于梯度的攻击，平均提高了至少 2.0% 的攻击成功率。这有力地证明了本章提出的方法无论是在 CNN 模型、基于 Transformer 的模型还是鲁棒模型上都具有强大攻击能力。这些出色的结果突出了在平坦区域定位对抗样本以提高可迁移性的有效性。

表 3-5 基于 Transformer 的模型在不同攻击方法下的攻击成功率（a）

模型	攻击	ViT-B/16	PiT-B	Vis-S	Swin	平均值
Res-18	VMI	28.7	38.9	54.2	58.0	45.0
	VNI	27.3	36.0	52.2	56.3	43.0
	EMI	21.3	29.6	45.6	52.6	37.3
	RAP	22.5	30.9	47.2	51.5	38.0
	PGN	32.4	42.8	57.4	66.4	49.8
	FFSA	42.7	54.6	70.0	75.7	60.8
Inc-v3	VMI	31.0	39.3	47.1	50.1	41.9
	VNI	28.0	37.4	47.5	49.8	40.7
	EMI	28.1	38.5	49.7	52.4	42.2
	RAP	30.4	40.9	55.4	55.4	45.5
	PGN	46.7	56.4	66.3	67.7	59.3
	FFSA	56.8	66.1	74.6	75.4	68.2

3.3.4 集成模型迁移攻击实验

除了攻击单一模型外，还在集成模型设置中评估了 FFSA 方法的性能，以进一步验证其有效性。在本小节中，采用了文献^[17]中的集成攻击方法，通过平均不同模型的 logit 输出创建集成。具体来说，对样本是通过整合两个正常训练的模型生成的，包括 Inc-v3 和 Inc-v4，表3-9中 * 表示白盒模型，加粗的数字表示最佳结果。所有集成模型都被赋予相等的权重，同时测试了在正常训练模型和对抗性训练模型上的可转移性性能。

表3-9中的结果表明，FFSA 方法在黑盒设置中始终实现了最高的攻击成功率。与以前的基于梯度的攻击方法相比，FFSA 实现了 94.45% 的平均成功率，分别超过了 VMI-FGSM、EMI-FGSM 和 RAP 12.42%、11.88% 和 7.37%。值得注意的是，FFSA 在对抗性训练模型上表现出更大的改进，平均超过了最佳攻击方法 PGN 超过 18.4%。这些结果验证有效地增强了对抗性攻击的可转移性，这也证实了本章提出的方法在对抗性攻击

表 3-6 基于 Transformer 的模型在不同攻击方法下的攻击成功率 (b)

模型	攻击	ViT-B/16	PiT-B	Vis-S	Swin	平均值
VGG16	VMI	22.5	33.4	47.8	52.0	38.9
	VNI	20.0	31.2	46.4	51.3	37.2
	EMI	16.2	24.6	40.4	46.4	31.9
	RAP	17.0	26.9	42.1	49.2	33.8
	PGN	27.0	38.5	53.5	61.5	45.1
	FFSA	35.7	53.4	65.6	73.3	57.0
ViT	VMI	98.4	55.4	57.2	66.6	69.4
	VNI	99.5	52.9	53.6	65.1	67.8
	EMI	99.3	61.3	65.6	75.9	75.5
	RAP	99.3	59.0	65.2	75.2	74.7
	PGN	97.6	76.3	76.1	81.6	82.9
	FFSA	96.1	76.1	76.0	80.3	82.1

表 3-7 鲁棒模型在不同攻击方法下的攻击成功率 (a)

模型	攻击	Inc-v3 _{ens3}	Inc-v3 _{ens4}	IncRes-v2 _{ens}	平均值
Res-18	VMI	59.8	62.6	68.5	63.6
	VNI	58.3	60.7	67.4	62.1
	EMI	55.3	62.4	65.3	61.0
	RAP	55.5	61.6	64.9	60.7
	PGN	75.3	77.8	77.6	76.9
	FFSA	80.1	81.1	80.6	80.6
Inc-v3	VMI	69.0	66.4	73.3	69.6
	VNI	67.1	64.8	72.2	68.0
	EMI	72.8	70.6	76.3	73.2
	RAP	77.8	72.4	78.8	76.3
	PGN	87.3	86.0	87.4	86.9
	FFSA	89.4	87.7	89.5	88.9

中的优越性。

3.3.5 与输入变换结合的攻击实验

现有的基于输入变换的攻击和其他攻击例如基于梯度的攻击之间具有良好的兼容性。由于本章提出的 FFSA 方法也是一种基于梯度的对抗攻击，所以可以很轻易的和这些基于输入变换的攻击结合起来使用，从而进一步提高对抗样本的迁移性。为了证明 FFSA 的有效性，分别选取了 DIM、TIM、SIM、Admix 和 SSM 方法，将结合了这些输入变换的 FFSA 分别称为 FFSA_{DIM}、FFSA_{TIM}、FFSA_{SIM}、FFSA_{Admix}、FFSA_{SSM}。通过在

表 3-8 鲁棒模型在不同攻击方法下的攻击成功率 (b)

模型	攻击	Inc-v3 _{ens3}	Inc-v3 _{ens4}	IncRes-v2 _{ens}	平均值
VGG16	VMI	52.2	55.7	63.2	57.0
	VNI	51.4	54.6	61.8	55.9
	EMI	49.3	53.1	61.8	54.7
	RAP	49.4	53.4	62.1	55.0
	PGN	66.3	69.4	73.0	69.6
	FFSA	72.8	72.1	76.8	73.9
ViT	VMI	52.9	54.9	63.1	57.0
	VNI	51.8	54.0	63.1	56.3
	EMI	58.2	59.3	67.3	61.6
	RAP	61.5	65.9	72.4	66.6
	PGN	71.6	68.9	76.7	72.4
	FFSA	69.4	69.7	75.1	71.4

表 3-9 集成模型设置中不同攻击方法下的无目标攻击成功率

Attack	Inc-v3	Inc-v4	Res-101	Inc-v3 _{ens3}	Inc-v3 _{ens4}	IncRes-v2 _{ens}	平均值
VMI	99.9*	99.5*	82.2	66.8	64.1	50.8	77.2
VNI	99.9*	99.4*	83.8	67.3	62.1	51.8	77.3
EMI	100.0*	99.9*	92.3	62.8	59.5	40.0	75.8
RAP	100.0*	99.4*	93.5	70.1	69.8	58.9	82.0
PGN	100.0*	99.9*	94.2	88.2	86.6	79.2	91.4
FFSA	100.0*	99.9*	96.8	94.5	90.1	85.4	94.5

Inc-v3 模型上生成对抗样本，并测试这些对抗样本在 6 个黑盒模型上的迁移性。

实验结果如表3-10所示，当结合 FFSA 的梯度更新策略时候，可以显著提高这些基于输入变换的攻击方法在黑盒设置中的对抗迁移性。同时 FFSA 在结合这些方法后性能也有了很大提升。例如，SIM 仅在七个模型上实现了 55.3% 的平均成功率，而当与 FFSA 方法结合时，它可以平均达到 83.4% 的成功率，比以前高出 28.1%。在结合这些基于输入转换的方法后，FFSA 在集成对抗训练模型上往往能取得更好的结果。这是一个显著的改进，表明该方法具有良好的可扩展性，并且可以与现有方法结合，进一步提高基于迁移的黑盒攻击的成功率。

3.4 本章小结

本章基于局部平坦极大值理论，提出了一种新的基于梯度优化的图像分类迁移对抗攻击算法 FFSA，即快速平坦近邻采样对抗攻击，该算法比现有的迁移攻击具有更高的迁移性和更少的计算复杂度。具体来说，FFSA 简化了每个迭代中随机采样平均梯度

表 3-10 FFSA 与不同输入变换方法结合使用的无目标攻击成功率

Attack	Inc-v3	Inc-v4	Res-101	Inc-v3 _{ens3}	Inc-v3 _{ens4}	IncRes-v2 _{ens}	平均值
DIM	99.9*	72.2	62.8	39.0	38.1	22.3	55.7
FFSA _{DIM}	99.9*	93.1	91.2	84.8	81.6	70.4	86.8
TIM	99.9*	51.6	47.8	29.6	30.7	20.5	46.7
FFSA _{TIM}	100.0*	91.4	83.7	83.9	81.5	78.0	86.4
SIM	100.0*	70.5	63.8	37.5	37.8	22.0	55.3
FFSA _{SIM}	100.0*	94.2	90.0	78.4	77.3	60.5	83.4
Admix	100.0*	78.6	69.5	41.6	40.3	16.4	57.7
FFSA _{Admix}	99.6*	93.1	88.9	72.4	70.8	52.4	79.5
SSM	99.7*	88.3	77.7	56.7	55.3	35.2	68.8
FFSA _{SSM}	99.4*	89.9	77.3	73.5	71.9	55.6	77.9

的计算方式，每次随机采样只计算一次梯度信息，不仅提高了对抗样本迁移能力，时间复杂度也从 $O(2N)$ 减少到 $O(N)$ 。对每次随机采样点周围子区域的上界进行随机调整，避免了固定上界造成的邻域信息损失。

在本章内容设计方面，首先引入了平坦局部极小值的概念，说明现有的算法重点关注损失的平坦极小值从而生成对抗样本，同时指出现有算法的问题所在。然后解释梯度范数和平坦局部极大值在生成对抗样本时的必要性，并介绍了基于此理论当前的最佳算法 PGN 的原理和问题。针对 PGN 的问题，介绍了本章提出的 FFSA 算法的理论依据和具体算法流程，并展示了使用 FFSA 生成的对抗样本。为了对本章提出方法生成的对抗样本进行分析，使用二维图的方式可视化损失函数，进一步从可解释角度验证了 FFSA 算法有效性和优越性。最后通过广泛的实验分析，包括单模型迁移攻击实验、集成模型迁移攻击实验和与输入变换结合的攻击实验，与其他 baseline 方法进行全面的对比，证明本章提出算法的迁移攻击能力超越其他基线方法，并具有良好的可扩展性，可以与其他基于输入变换的方法结合进一步提高迁移性。

4 基于增强特征失真的目标检测可迁移对抗攻击

4.1 问题与挑战

本研究已经在第三章重点研究了图像分类网络面临的对抗样本威胁,除此之外,最近的研究表明,目标检测网络等密集预测模型也很容易受到对抗样本攻击的影响。图像分类和目标检测在深度学习中是两个不同的任务,现有的研究大多集中在针对图像分类网络的对抗样本生成,针对目标检测的对抗样本生成算法研究较少。最近的研究大多只能对单一白盒模型进行攻击,在其他黑盒模型上的迁移攻击能力不强。为了进一步深入了解目标检测模型的鲁棒性,有必要对目标检测对抗样本迁移攻击进行深入研究。

4.2 目标检测对抗样本迁移性分析

近年来,通过干扰神经网络中间层特征对分类器进行可迁移对抗攻击的方法得到了广泛的研究。然而,这些方法在直接应用于目标检测器时尚未取得令人满意的性能,这在很大程度上是因为检测器的特征与分类器的特征有根本的不同。

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
		3×3 max pool, stride 2				
conv2_x	56×56	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

图 4-1 Resnet 的网络结构

与分类器相比,检测器通常具有多样化和更灵活的架构,包括主干网络(backbone)[58, 94–97]、颈部(neck)[34, 35, 98, 99]和头部(head)组件,这为可迁移对抗性攻击带来了更多的挑战。虽然颈部和头部组件在不同的检测器中差异很大,但主干网络通常表现出显著的相似性,甚至不同目标检测器之间共享某些特定的主干网络。例如 VFNet、FRCNN、FCOS 和 DETR 等目标检测模型都采用 Resnet^[58] 作为 Backbone,除此之外 YOLOv3 的主干网络 DarkNet53 也和 Resnet 类似:一种采用了残差结构的卷积神经网络。作为模型的核心部分,主干网络负责从输入图像中提取特征,生成特征图,通常采用深度卷积神经网络,如 ResNet、VGG、EfficientNet 等。如图4-2是 FRCNN 目标检测器的 DarkNet53 骨干网络结构,图4-1是 Resnet 的网络结构,他们本质上是一类模型。

这些网络通过多层卷积操作自动学习图像中的边缘、纹理、形状等特征，为后续的目标检测提供基础。因此可以通过对目标检测模型的主干网络进行攻击，获得具有强大黑盒迁移攻击能力的对抗样本。

根据主干网络特征的特性来设计攻击可以是一个增强对抗迁移能力的方法。然而，现有的针对目标检测器的无目标攻击^[24, 44, 45, 47] 主要侧重于利用模型输出和特定任务的损失函数来生成恶意扰动，往往使得制作的对抗样本过拟合模型的结构，黑盒迁移攻击能力较弱。

现有攻击方法如 DAG^[44]、CAP^[24] 和 TOG^[47] 主要优化目标检测器特有的损失函数 $\mathcal{L}_{det}$ ，即：

$$\mathcal{L}_{det} = \lambda_{obj} \mathcal{L}_{obj} + \lambda_{cls} \mathcal{L}_{class} + \lambda_{loc} \mathcal{L}_{loc} \quad (4-1)$$

其中 $\mathcal{L}_{obj}$ 、 $\mathcal{L}_{class}$ 、 $\mathcal{L}_{loc}$ 分别代表目标置信度损失函数、类别损失函数和边界框定位损失函数，分别是三种相应损失函数的 loss 权重。尽管 UEA 攻击^[46] 采取进一步扰动检测器的中间层特征的方法，但对这些特征处理的欠缺导致对抗迁移攻击能力仍有待提高。

	Type	Filters	Size	Output
1x	Convolutional	32	3 × 3	256 × 256
	Convolutional	64	3 × 3 / 2	128 × 128
	Convolutional	32	1 × 1	
	Convolutional	64	3 × 3	
	Residual			128 × 128
2x	Convolutional	128	3 × 3 / 2	64 × 64
	Convolutional	64	1 × 1	
	Convolutional	128	3 × 3	
	Residual			64 × 64
8x	Convolutional	256	3 × 3 / 2	32 × 32
	Convolutional	128	1 × 1	
	Convolutional	256	3 × 3	
	Residual			32 × 32
8x	Convolutional	512	3 × 3 / 2	16 × 16
	Convolutional	256	1 × 1	
	Convolutional	512	3 × 3	
	Residual			16 × 16
4x	Convolutional	1024	3 × 3 / 2	8 × 8
	Convolutional	512	1 × 1	
	Convolutional	1024	3 × 3	
	Residual			8 × 8
	Avgpool		Global	
	Connected		1000	
	Softmax			

图 4-2 DarkNet53 的网络结构

与攻击图像全局像素相比，攻击包含待检测对象及其附近区域对检测结果的影响更大。这是因为检测器更多地依赖图像中目标的局部区域进行精确的对象定位，而分类器主要利用图像全局信息进行类别预测。检测器的主干网络对于包含对象的区域投入更多的注意力，这些区域被称为重要特征，使后续的颈部和头部组件能够定位对象的位置。如图4-8第一行图片所示，高亮区域即为目标检测器的注意力集中点。因此，这些重要特征具有两个关键特性：

(1) 空间敏感一致性，表明它们在特征图中的位置与图像中对象的位置紧密匹配。检测器的特征张量 $F_i \in \mathbb{R}^{C \times H \times W}$ 包含明确的空间位置信息，通过反卷积操作可实现特征激活位置与原始图像像素的精确对应^[100]

(2) 有限等变特性：对于输入图像变换 T ，检测器 F 满足 $T(F(x)) \approx F(T(x))$ 的

条件等变性，但当 T 的变换幅度超过阈值时，该等变关系将失效，即从经过一定程度数据增强的图像中提取的特征与直接应用相同增强后获得的特征大致等效。

4.3 算法设计

4.3.1 算法概述

针对以上对目标检测模型结构和对抗样本迁移性的分析，本章提出了一种简单而有效的方法来提高基于目标检测器构建的对抗样本的可迁移性，该方法利用了目标检测器特征的空间一致性和有限等变特性，通过抑制与对象对应的重要特征并放大对象周围邻近特征来扭曲对象检测器的骨干网络中每一层特征。因此，生成的对抗样本中的目标对象和背景区域更有可能被其他检测器误判。

本章提出的基于增强特征失真的目标检测可迁移对抗攻击（Enhancing Feature Distortion Attack, EFDA）包括两部分：双路径特征失真度量框架和输入变换方法 SRR，通过两者联合作用来抑制重要特征并有效放大非重要特征，从而增强目标检测无目标对抗攻击迁移性，算法总体流程如图4-3所示。

本章的创新点可总结为：

（1）提出双路径特征失真度量框架，构建具有双约束项的目标检测对抗攻击损失函数 L_{EFDA} ，统一优化特征的幅度和方向属性，从多尺度特征层面生成高可迁移性的对抗样本。

（2）提出了输入变换方法 SRR，由随机网格打乱、随机轴旋转、自适应随机大小调整和高斯模糊组成，通过在对抗样本生成过程中使用 SRR 输入变换，有效地扭曲了目标及其附近的重要特征。




图 4-3 EFDA 攻击流程

整体攻击流程总结如下：

(1) 输入原始图像 x 和目标检测器的骨干网络 F ，初始化对抗样本 $x^{adv} = x$ 。对抗样本是通过将良性图像与对抗样本结合构建的，其中对抗样本作为算法的优化目标。

(2) 然后应用本文提出的 SRR 输入变换方法，用 T 表示，即首先并行使用随机的网格打乱、轴旋转、调整大小来增强对抗样本，最后对每个变换结果执行高斯模糊。即 $x^{adv} = T(x)$

(3) 提取通过 SRR 增强的对抗样本的特征，并将其与放大的良性特征结合，以计算并最大化损失函数 L_{EFDA} ，在反向传播后获取梯度 g_t

(4) 使用动量法更新对抗样本并将对抗扰动限制在特定范围内，完成攻击的一个 step。通过若干个这样的 step 生成最终的对抗样本。

通过这样的攻击流程在保持对白盒代理模型的强大攻击能力的同时也对不同的黑盒模型具有超越以往方法的迁移攻击能力。使用 YOLOv3 作为替代模型生成对抗样本的检测结果如图4-4所示。通过图像可以发现，增强特征失真攻击方法扰乱了原始对象检测边界框，并在对象及其邻近区域产生了额外的干扰框，通过将攻击限制在对象及其附近区域，显著增强了对抗样本的迁移能力。对于不同黑盒模型攻击的检测结果显示在实验部分中展示，如图4-9和图4-10所示。




图 4-4 对 YOLOv3 白盒攻击的检测结果

4.3.2 针对内部特征的对抗攻击

基于神经网络内部特征生成的对抗样本具有高度的泛化能力，因此，在模型内部特征空间中产生最大扰动的攻击可以生成高度可迁移的对抗样本。除此之外，这周攻击方法可以在不同的架构中针对不同的任务进行推广，而不依赖特定任务的损失函数，这被视为一种有效的对目标检测网络进行黑盒攻击的方式。

Zhou 等人^[101] 通过加入衡量原始图片和对抗图像中间特征图的距离的中间损失函数，从而能在少量步数内依靠中间损失函数的梯度最大化损失函数，这种方法也被称作 TAP。原始图像和对抗图像的中间特征图存在较大距离最终会导致神经网络对于两者的最终输出以高概率产生较大距离，这会使得损失函数增大并导致模型做出错误预测。基于此，TAP 添加了一个中间损失，该损失衡量输入 x 和对抗样本 x^{adv} 之间中间特征图的距离。中间损失相对于输入 x 的梯度足以在几步内最大化中间损失。此外，这些梯度还提供了更新方向，以最大化损失函数 2-1。输入 x 和 x^{adv} 之间中间特征图的较大距离最终将导致神经网络最终输出的较大距离，从而增大损失函数 2-1 并产生错误预测。令 $L(x, d)$ 表示层 $d \in D$ 中的中间特征图，最大化所有层中 $T(L(x, d))$ 和 $T(L(x^{adv}, d))$ 之间的 l_2 范数距离，其中 $T(L(x^{adv}, d))$ 表示 $L(x^{adv}, d)$ 的幂归一化^[102]。幂归一化用于降低 $L(x, d)$ 中大值的贡献，属于特征归一化的一种方式，定义如下：

$$T(L(x^{adv}, d)) = \text{sign}(L(x^{adv}, d)) \odot |\text{abs } L(x^{adv}, d)|^\alpha \quad (4-2)$$

其中 $0 \leq \alpha \leq 1$ 是归一化的一个参数， $\odot$ 表示逐元素乘积。作者发现上述转换对于黑盒迁移非常有效。通过最大化输入 x 和对抗样本 x^{adv} 之间中间特征图的距离，生成对抗样本如下：

$$x^{adv} = \arg \max_{\|x^{adv} - x\|^p \leq \epsilon} \left(l(x^{adv}, y) + \lambda \sum_{d \in D} \|T(L(x, d)) - T(L(x^{adv}, d))\|^2 \right) \quad (4-3)$$

其中 λ 表示损失 2-1 和中间损失之间的权衡， $l(x^{adv}, y)$ 表示白盒模型的损失函数。为了使每层的特征平等地贡献，使用 min-max 缩放将 $L(x, d)$ 归一化到 $[0, 1]$ 。同时引入了对扰动的正则化，以更有效地减少变化：

$$\begin{aligned} x^{adv} &= \arg \max_{\|x^{adv} - x\|^p} J_{TAP}(x^{adv}, x, y, w_s) \\ &= \arg \max_{\|x^{adv} - x\|^p \leq \epsilon} (l(x^{adv}, y) \\ &\quad + \lambda \sum_{d \in D} \|T(L(x, d)) - T(L(x^{adv}, d))\|^2 \\ &\quad + \eta \sum_i \text{abs} R_i(x^{adv} - x, w_s)) \end{aligned} \quad (4-4)$$

J_{TAP} 表示 TAP 的损失函数， η 控制正则化和损失函数之间的平衡。 $R_i(x^{adv} - x, w_s)$ 表示响应图中的第 i 个元素，该元素通过核 w_s （大小为 s ）和扰动 $x^{adv} - x$ 之间进行卷积计算得出。 w_s 设计为盒式线性滤波器，这是一种空间域线性滤波器，其中结果图像中的每个像素的值等于输入中其邻近像素的平均值。它是一种低通滤波器，强制邻近像素的连续性并减少对抗扰动的变化。

TAP 方法仅限于分类任务，因为梯度方向依赖于交叉熵损失，这需要手动设置任务的标签。因此，这种攻击算法本质上是一种有监督的对抗攻击。相比之下，Nasser 等人^[25] 提出的 NRDM 不使用任何依赖于任务的损失，因此这种攻击方法不依赖于任何标签，是一种无监督的对抗攻击。Nasser 等人认为当前试图增强对抗性可转移性的攻

击算法在决策级别工作，即产生改变网络决策的扰动。这导致了两个关键限制：(a) 攻击依赖于特定任务的损失函数（例如用于对象识别的 softmax 交叉熵），因此不会推广到其原始任务之外。(b) 对抗性样本特定于网络架构，并表明对其他网络架构的可转移性很差。在此基础上 NRDM 可以用来生成跨不同网络架构，跨不同视觉任务（例如，图像分割、分类和目标检测）转移的高强度对抗性样本，也是一种基于神经网络内部表示的黑盒无目标对抗攻击算法。MI-FGSM 和 TIM 等迁移攻击对特定任务损失函数的依赖使它们不能跨不同任务转移。例如，为了欺骗分类模型，攻击者从 softmax 交叉熵开始寻找增加给定样本模型损失的梯度方向。以这种方式找到的对抗样本是特定的，不会超出其原始任务。

计算原始图像和对抗样本之间的均方差来表示神经表示失真（Neural Representation Distortion, NRD），NRD 是完全可微的，它的最小化有助于图像恢复问题^[103]。通过最大化 NRD 来构建对抗性扰动，从而提高对抗样本的黑盒迁移性。基于特征表示寻找对抗性示例使本章的攻击可以在不同的架构中针对不同的任务进行推广。通过解决以下优化问题来最大化基于深度特征激活表示损失的感知度量：

$$\begin{aligned} \max_{x^{adv}} \quad & \mathcal{F}(x^{adv})|_k - \mathcal{F}(x)|_k \\ \text{subject to: } & \|x - x^{adv}\|_\infty \leq \epsilon \end{aligned} \quad (4-5)$$

其中 $\mathcal{F}$ 是基于深度神经网络（DNN）的分类器， k 是内部表示层， ϵ 是允许的扰动预算。

Ganeshan 等人^[22] 提出了特征破坏性攻击 FDA，通过生成图像扰动，破坏网络每一层的特征，并导致深度特征高度损坏，使得可以严重降低深度网络的性能。即使无法访问特定任务的网络或方法，也会破坏基于特征表示的任务。与 Zhou 等人^[101] 通过同时优化多个目标（包括最终层交叉熵项）来创建黑盒可转移对抗样本不同，FDA 只针对特征中断的公式进行优化。作者认为因为 PGD、C&W、MI-FGSM 这些攻击仅优化 pre-softmax 或基于 softmax 分数的目标以生成对抗性样本，通过这种方式生成的对抗样本的深层特征保留了相应干净样本的高级语义信息，同时这种深度特征可能仍然适用于各种特征驱动的任务（例如图像字幕生成^[104, 105] 和风格迁移^[106]）。这些对抗性样本导致模型要么预测语义相似的类，要么为原始标签保留高（相对）概率，同时预测一个非常不同的类。

4.3.3 双路径特征失真度量框架

基于网络中间特征失真的攻击在不同的任务中具有强大的迁移攻击能力，本章基于此设计了一种双路径特征失真度量框架，通过最大化对抗样本和原始图像的中间特征图距离来生成目标检测对抗样本。

对于检测器的主干网络部分，它通常涉及 $n(n \geq 1)$ 个阶段用于特征提取。将第 i 阶段的特征表示为 $F_i \in \mathbb{R}^{C \times H \times W}$ ，其中 i 是从 1 到 n 的整数。考虑到检测器的空间一致性和有限的等变性，本章旨在设计损失函数 $\mathcal{L}$ 并采用输入变换方法来使得主干部分特征失真，从而扰乱原始对象及其周围区域的重要特征，实现强大的迁移攻击能力。

给定一个良性图像 x ，通过攻击一个白盒代理检测器，可以制作其对应的对抗样本 x^{adv} ，该样本可以有效地迁移到多个黑盒检测器。这个优化问题可以表述为公式4-6，其中 $\mathcal{L}$ 是一个用于扰动模型输出或内部层的损失函数，并且采用 l_p 范数来衡量 x 和 x^{adv} 之间的距离。在本研究中的 $\mathcal{L}$ 用来衡量模型中间层的特征差异。

$$\arg \max_{x^{adv}} L, \text{ s.t. } \|x^{adv} - x\|_p \leq \epsilon \quad (4-6)$$

对于双路径特征失真度量框架，其核心在于建立多尺度特征一致性约束。在损失函数设计方面，由两部分组成： $\mathcal{L}_{MSE}$ 和 $\mathcal{L}_{Cosim}$ 。均方误差（MSE）损失 $\mathcal{L}_{MSE}$ 的计算通过乘以一个常数 k 来放大良性特征的值作为幅度失真项，其中 $k \geq 1$ ，计算方式如公式4-7所示。损失函数 $\mathcal{L}_{Cosim}$ 即方向失真项，衡量同一层网络提取特征的余弦相似度，计算方式如公式4-8所示。EFDA 的双路径特征失真损失函数 $\mathcal{L}_{EFDA}$ 可以表述为公式4-9，其中 n 是特征中的总阶段数， $F_{ij}(\cdot)$ 表示第 i 阶段特征的第 j 个元素，其中包含 N_i 个元素项，其中 $\mathcal{L}_{EFDA} = \mathcal{L}_{MSE} + \beta \cdot \mathcal{L}_{Cosim}$ 。

$$\mathcal{L}_{MSE} = \sum_{i=1}^n \frac{1}{N_i} \sum_{j=1}^{N_i} (F_{ij}(T(x^{adv})) - k \cdot F_{ij}(x))^2 \quad (4-7)$$

$$\mathcal{L}_{Cosim} = 1 - \sum_{i=1}^n \frac{F_i(T(x^{adv})) \cdot F_i(x)}{\|F_i(T(x^{adv}))\|_2 \cdot \|F_i(x)\|_2} \quad (4-8)$$

$$\begin{aligned} \mathcal{L}_{EFDA} &= \mathcal{L}_{MSE} + \beta \cdot \mathcal{L}_{Cosim} \\ &= \sum_{i=1}^n \frac{1}{N_i} \sum_{j=1}^{N_i} (F_{ij}(T(x^{adv})) - k \cdot F_{ij}(x))^2 + \beta \cdot \left(1 - \sum_{i=1}^n \frac{F_i(T(x^{adv})) \cdot F_i(x)}{\|F_i(T(x^{adv}))\|_2 \cdot \|F_i(x)\|_2} \right) \end{aligned} \quad (4-9)$$

其中 $\mathcal{L}_{MSE}$ 称为幅度失真项， $\beta \cdot \mathcal{L}_{Cosim}$ 称为方向失真项。 $T(\cdot)$ 表示在特征提取之前对抗样本进行的输入变换。EFDA 目标检测对抗攻击伪代码如算法4-1 所示。

不同损失的值差异（如相差 10 倍）会直接影响梯度的计算方向和幅度。因为梯度是总损失对模型参数的导数，若某项损失数值显著更大，其梯度分量会主导反向传播的更新方向。这里的 β 是超参数，表示方向失真项权重，能够使得使幅度失真项和方向失真项两者加权后的数值量级相近，从而稳定梯度更新方向。

MSE 是欧氏距离的平方的均值，两者共享核心计算部分（平方差的和），因为平方是单调函数，所以优化 MSE 等价于优化欧氏距离的平方。余弦相似度在高维空间中聚焦方向而非强度，是衡量特征相似性的有效工具，尤其适合文本、图像等稀疏高维数据。Bellman 等人^[107] 在考虑优化问题时首次提出维度灾难的概念，由于在高维空间中存在维度灾难（Curse of Dimensionality），即所有点之间的欧氏距离会趋近于相似值，导致区分度下降，此时两个特征向量直接的余弦相似度更能反应特征相似程度。如图4-5和图4-6所示，对于从 2 到 1000 不同的维度，每个维度下随机采样 1000 个样本，得到了不同维度下 MSE 和余弦相似度的箱线图，可以看出当维度增加至 1000 时，MSE 的特

算法 4-1 增强特征失真攻击 EFDA

Input: 骨干网络 $F(\cdot)$, 输入样本 x , 输入变换 $T(\cdot)$, 放大因子 k , β , 衰减因子 μ , 最大扰动 ϵ , 迭代次数 S

Output: 对抗样本 x^{adv} 使得 $\|x^{adv} - x\|_{\infty} \leq \epsilon$

```

1 Initialize:  $g_0 = 0$ ;  $x_0^{adv} = x$ ;  $\alpha = \epsilon/S$ 
2 for 迭代次数  $t = 0, \dots, S - 1$  do
3   if  $t = 0$  then
4      $x_t^{adv} = T(x)$ 
5   end
6   将  $x_t^{adv}$  传递给  $F$  并计算  $\mathcal{L}_{EFDA}$  :
7    $\mathcal{L}_{EFDA} = \mathcal{L}_{MSE} + \beta \cdot \mathcal{L}_{Cosim}$ 
8   其中  $\mathcal{L}_{EFDA}$  由公式4-9得到
9   计算梯度  $g_t$ :
10   $g_{t+1} = \mu \cdot g_t + \frac{\nabla_x \mathcal{L}_{EFDA}(x_t^{adv}, x)}{\|\nabla_x \mathcal{L}_{EFDA}(x_t^{adv}, x)\|_1}$ 
11  应用 MI-FGSM 算法更新  $x_t^{adv}$ :
12   $x_{t+1}^{adv} = x_t^{adv} + \alpha \cdot \text{sign}(g_{t+1})$  将对抗样本投影到  $x$  的附近, 即:
13   $x_{t+1}^{adv} = \text{clip}(x_{t+1}^{adv}, x - \epsilon, x + \epsilon)$ 
14 end
15 return  $x^{adv} = x_S^{adv}$ 

```

征区分度快速下降, 而余弦相似度对特征依旧存在明显的区分度。对于两个特征, 余弦相似度越大相似度越高, 所以在方向失真项中需要设置 $\mathcal{L}_{Cosim} = 1 - \text{余弦相似度}$ 。




图 4-5 不同维度下 MSE 的分布




图 4-6 不同维度下余弦相似度的分布

4.3.4 基于 SRR 的输入变换

输入变换已成为提高对抗可迁移性的最有效方法之一。多样化输入法 (DIM)^[13] 首先将图像调整为随机大小，并在梯度计算之前将填充添加到固定大小。平移不变法 (TIM)^[16] 将图像转换为一组图像进行梯度计算，通过用高斯核对梯度进行卷积来近似。尺度不变法 (SIM)^[14] 计算几个缩放图像的梯度。Admix^[15] 将来自其他类别的一小部分图像混合到输入图像中，以制作一组混合图像。为了进一步增强对抗样本迁移能力，针对目标检测任务本章设计了一种新的输入变换方法 SRR，包括以下几种图像变换方式：

(1) 随机网格打乱 (Random block shuffle)：将图像随机拆分为 $n \times n$ 个网格块，然后将这些网格块的顺序进行随机打乱。

(2) 随机轴旋转 (Random axis rotation)：对于给定的图像 z ，可以从标签中提取对象边界框中心的坐标和整个图像的中心。从以这些中心点为中心、边长为 l_s 的正方形区域中随机抽取一个坐标作为每个数据增强步骤的旋转轴。然后围绕选定的旋转轴以随机角度 ϕ 旋转图像，其中 $\phi \in [-\theta, +\theta]$ ， θ 表示预定义的最大旋转角度。

(3) 自适应随机调整大小 (Adaptive random resizing)：采用 DIM^[13] 中的数据增强方式，即调整大小并填充 (Resizing and Padding) 模式，并根据对象的大小引入自适应缩放因子 s ，在增强过程中限制最大填充空间 p 。

$$s_h = \min \left(1 + \rho \times \frac{b_h}{I_h}, s_{\max} \right) \quad (4-10)$$

高度的缩放因子 s_h 是使用公式4-10计算的，其中 b_h 和 I_h 分别是边界框和图像的高度， $\min(\cdot, \cdot)$ 表示取最小值。 $s_{\max}$ 是一个用于限制 s 的常数， ρ 是一个用于调整增强强度和边界框大小之间关系的参数。图像调整大小后应用的填充空间的最大高度 p_h 可以表示

为公式4-11。

$$p_h = (s_h - 1) \times I_h \leq \rho \times b_h \quad (4-11)$$

宽度的缩放因子 s_w 和填充空间的最高高度 p_w 可以类似地根据公式4-10和4-11计算。对于图像中存在多个对象的情况，在每次增强过程中随机选择一个对象的边界框来计算参数 s 。

(4) 高斯模糊 (Gaussian Blurring): 在并行进行前三种输入变换之后，在图像中添加高斯噪声用来增加随机扰动，让生成的对抗样本更具多样性，使得攻击更难被防御。输入变换效果如图4-7所示。



图 4-7 不同输入变换效果展示

除了与双路径特征失真度量框架一起使用以外，SRR 也可以单独使用来增强迁移攻击，例如可以使用 NRDM 攻击中的损失函数，在计算对抗样本更新梯度时首先对输入进行 SRR 变换，然后计算平均梯度。基于 SRR 输入变换计算平均梯度的公式如下：

$$\bar{g} = \frac{1}{N} \sum_{i=0}^N \nabla_{\mathbf{x}^{adv}} \mathcal{L}(T_i(\mathbf{x}^{adv}, n, \theta, \rho)) \quad (4-12)$$

其中 $\mathcal{L}$ 表示损失函数，与 EFDA 攻击结合的情况下 $L = L_{EFDA}$ 。N 表示采取的输入变换数量， T_i 表示一种输入变换方法，这里由于采用了三种输入变换方法且每种随机采

样两次，所以 $N = 6$ 。 n 、 ρ 和 θ 分别是随机网格打乱和随机轴旋转中的超参数。

算法 4-2 基于 SRR 输入变换的对抗攻击

Input: 一个具有参数 θ 的分类器 f ，损失函数 $\mathcal{L}$ ；一个原始样本 x 及其真实标签 y ；扰动的大小 ϵ ；迭代次数 T ；衰减因子 μ ；变换图像的数量 N ；网格的数量 n ；旋转的最大角度 τ

Output: 一个对抗样本 x^{adv}

```

1  $\alpha = \epsilon/T, g_0 = 0$ 
2 for  $t = 1 \rightarrow T$  do
3   生成  $N$  个变换后的图像:  $T(x^{adv}, n, \tau)$ 
4   计算平均梯度  $\bar{g}_t$ :
      
$$\bar{g}_t = \frac{1}{N} \sum_{i=0}^N \nabla_{\mathbf{x}^{adv}} \mathcal{L}(T_i(\mathbf{x}^{adv}, n, \theta, \rho))$$

      更新动量  $g_t$ :
      
$$g_t = \mu \cdot g_{t-1} + \frac{\bar{g}_t}{\|\bar{g}_t\|_1}$$

      更新对抗样本:
      
$$x_t^{adv} = x_{t-1}^{adv} + \alpha \cdot \text{sign}(g_t)$$

5 end
6 return  $x_T^{adv}$ 

```

4.3.5 对抗样本可解释性分析

本章使用 Grad-CAM (Gradient-weighted Class Activation Mapping) 方法对生成的对抗样本进行可视化分析，从而对本章提出的对抗攻击成功扰乱图像重要特征的过程进行解释。Grad-CAM 通过反向传播梯度来定位输入图像中对模型预测结果贡献最大的区域，生成注意力热力图 (Attention Heatmap)，从而可视化模型的决策依据。它结合了卷积层的特征图和梯度信息，无需修改网络结构，具有模型无关性，即仅依赖梯度和特征图，可应用于不同任务 (分类、检测等)，但需确保输出可微分。Heatmap 的生成包括以下几个步骤：

(1) 特征图提取：选择模型的最后一层卷积层 (或某个中间卷积层) 作为目标层，获取该层的特征图 (Feature Maps)，即模型对输入图像提取的多通道局部特征。

(2) 梯度计算：对目标类别的分类分数 (Logits 或 Softmax 输出) 求梯度，反向传播至目标卷积层，梯度反映了每个特征图通道对目标类别的重要性。

(3) 权重生成：对每个特征图通道的梯度进行全局平均池化 (Global Average Pooling)，得到权重向量 α_k^c ，即：

$$\alpha_k^c = \nabla^c \cdot \text{AvgPool}(A^k) = \frac{1}{Z} \sum_{i,j} \frac{\partial Y^c}{\partial A_{i,j}^k} \quad (4-13)$$

其中 c 代表目标类别， k 代表特征图的第 k 个通道， A^k 代表第 k 个特征图， Y^c 是目标类别的输出分数， $A_{i,j}^k$ 是特征图第 k 通道在位置 (i, j) 的值， Z 是特征图的空间维度（宽 $\times$ 高）。

(4) 加权特征图叠加：将权重与对应的特征图通道相乘后求和，生成粗略的热力图 L^c ，即：

$$L^c = \sum_{k=1}^K \alpha_k^c \cdot A^k \quad (4-14)$$

(5) 后处理：对热力图进行 ReLU 激活（仅保留正值），并上采样到原始图像尺寸，最终叠加到原图上，公式如下：

$$L^c = \text{ReLU} \left(\sum_{k=1}^K \alpha_k^c \cdot A^k \right) \quad (4-15)$$

热力图 L^c 高亮模型关注的区域（值越大颜色越深表示越重要）。这种方法无需全连接层，传统 CAM 需要全连接层连接特征图与分类输出，而 Grad-CAM 直接通过梯度计算权重，适用于任意模型结构。

如果应用在目标检测任务中会出现一个问题：目标检测模型（如 Faster R-CNN）的输出（边界框、类别）经过非可微处理（如 NMS、类别 argmax ），无法直接使用 Grad-CAM。这就需要自定义目标函数，将检测结果（如边界框的 IOU 和类别分数）作为可微分的优化目标。为此，本章使用梯度自由方法 EigenCAM 和自定义目标函数间接利用 Grad-CAM。在 Faster R-CNN 中，需指定目标层（如 backbone 的特征金字塔）和 reshape 转换，以聚合多尺度特征。

针对 Faster R-CNN 的骨干网络即特征金字塔（FPN），将这一部分计算出有意义的激活值并进行处理，检测器网络的剩余部分会从这里提取特征然后预测边界框。由于骨干网络输出的格式非常特殊，包括 FPN 的 5 个不同的张量（Tensor），它们具有不同的空间大小并存储在一个有序的字典中。所以目标应该是聚合这些图像张量、分配相应的权重并汇总。为此，将这些不同大小的张量调整为相同的形状并进行拼接。除此之外，与使用了 ReLU 激活函数的分类网络不同，检测器的 FPN 激活值是无界的，存在负值，所以这里对激活值取绝对值来解决这一问题。在目标检测的情况下，模型的输出是边界框及其类别。但是 Faster-RCNN 并没有返回所有类别的分数，它只返回最高分数的类别。所以必须为 Faster-RCNN 的输出定义一个目标分数，用于评估模型输出的边界框与原始检测的匹配程度，突出显示图像中与目标检测最相关的部分，最后生成 CAM 注意力热力图，边界框评分算法如4-3所示。

如图4-8所示，第一行显示的是原始图像输入 FRCNN 的注意力热力图，可以观察到注意力连续集中在目标的重点位置。第二行显示的是基于 YOLOv3 生成的对抗样本输入 FRCNN 的注意力热力图，明显可以观测到模型对于对抗样本的注意力被分散在

算法 4-3 Faster-RCNN 边界框评分算法

Input: 模型输出 M_{out} , 原始边界框 $boxes$, 原始标签 $labels$, 交并比阈值 ϵ

Output: 目标分数 $output$

```

1 初始化目标分数  $output = 0$ 
2 if 模型输出的边界框数量为 0 then
3   | return  $output$ 
4 end
5 for 每个原始边界框  $box$  和其对应标签  $label$  do
6   | 计算  $box$  与模型输出边界框的交并比  $iou_s$ 
7   | 找到与  $box$  交并比最大的模型输出边界框索引  $i$ 
8   | if  $iou_s[0, i] > \epsilon$  且索引为  $i$  的模型输出标签  $== label$  then
9   |   | 计算分数  $score = iou_s[0, i] + label$ 
10  |   | 更新目标分数  $output = output + score$ 
11  | end
12 end
13 return  $output$ 

```




图 4-8 FRCNN 的注意力热力图

无关区域尤其是目标周围区域中，进而导致检测出错，通过这样的可解释方法进一步证明了本章提出的增强特征失真对抗攻击的强大迁移攻击能力。

4.4 实验与结果分析

4.4.1 数据集

本实验采用了一种数据集：VOC2012。从 VOC2012 数据集中随机选取了 2000 张图片并转换为 COCO 数据标注格式，每个图像都调整为 800×800 ，用零填充。

4.4.2 对比方法

本章选择了四个代表性模型，包括 YOLOv3^[43]、VFNet^[108]、FasterRCNN^[42] 和 MaskRCNN^[109]，作为生成对抗样本的源模型。这四个模型的主干网络分为基于 CNN 的模型，包括 Darknet-53^[43]、ResNet-50^[58]、ResNet-101^[58]，以及基于 Transformer 的模型，包括 Swin-Transformer^[96]。此外，YOLOv3 和 VFNet 分别是基于锚点和无锚点的单阶段检测器，而 FasterRCNN 和 MaskRCNN 是双阶段检测器。为了进一步验证对抗样本在不同检测架构中的可转移性，额外选择了 YOLOF^[110]、YOLOX^[111]、FCOS^[112] 和 DETR^[113] 检测器作为目标模型。这些模型提供了更多的主干网络，包括 CSPDarknet 和各种颈部及头部设计，如 DETR。MaskRCNN 和 DETR 是基于 Transformer 的，而表4-4中的其他六个检测器是基于 CNN 的。所有模型都使用 mmdetection 框架在 COCO 数据集上进行了良好的训练。

本章选择了四种特征级别的对抗攻击，即 NRDM^[25] 和 FDA^[22]，作为仅攻击特征的方法的代表，以及 NAA^[29] 和 RPA^[28]，作为基于聚合梯度方法的代表。在检测器的对抗攻击方面，TOG 相比于 UEA 和 RAP 表现出更优越的性能。其他方法^[48] 主要关注定向攻击。因此，选择 TOG 作为目标检测器的最新方法，因为它可以直接最大化训练损失以实现无目标攻击。所有比较方法默认与 MI-FGSM 和 DIM 集成，以实现更好的可迁移性。

为了评估对抗样本在源模型和目标模型上的有效性和可转移性，本章使用了 COCO 数据集的主要挑战指标作为评估标准。实验中的 mAP 指标计算了在十个不同的 IoU 阈值下的 AP，范围从 0.5 到 0.95，间隔为 0.05，这提供了对模型性能更可靠和准确的评估。在本章中，对所有方法执行了 200 次攻击步，从而产生足够强大的对抗样本。

4.4.3 实验设定

在本实验中硬件设置与第三章保持一致，软件设置有所不同，主要是引入了额外的 mmdetection 框架从而支持目标检测任务，除此之外引入了

在所有实验中，使用 l_∞ 范数作为约束，最大扰动 $\epsilon = 5/255$ 。对于本章的方法，为所有四个白盒代理模型设置了放大因子 $k = 3$ ， $\beta = 2$ 。对于随机轴旋转，设置了一个大小为 $l_s = 10$ 的中心区域，最大旋转角度为 $\theta = 7^\circ$ 。对于自适应随机调整大小，设置了参数 $\rho = 0.8$ 和 $s_{\max} = 1.1$ 。对于高斯模糊，设置了均值 $\mu = 0$ 和标准差 $\sigma = 6.0$ 。

4.4.4 评价指标

本章使用 mAP 对对抗样本的攻击效果进行评估，在目标检测中通常使用全类平均精度（Mean Average Precision, mAP）来对模型的性能进行评估，在本章中 mAP 越小说明对抗攻击效果越好。mAP 是一种综合衡量模型性能的核心指标，其计算原理基于不同类别的平均精度（AP）的综合评估。基本定义：mAP 是所有类别 AP（Average Precision）的平均值。AP 代表单个类别在精确率（Precision）和召回率（Recall）曲线下的面积，而 mAP 则通过平均所有类别的 AP 值来反映模型在多类别任务中的整体性能。

(1) 单类别平均精度（AP）：对于某一类别，AP 定义为 Precision-Recall（PR）曲线下的面积，公式为：

$$AP = \int_0^1 P(r) dr \quad (4-16)$$

其中， $P(r)$ 是召回率 r 对应的精确率。

AP 的两种计算方法：VOC 2007 的 11 点插值法：

$$AP = \frac{1}{11} \sum_{r \in \{0, 0.1, \dots, 1.0\}} P_{\text{interp}}(r) \quad (4-17)$$

其中 $P_{\text{interp}}(r) = \max_{\tilde{r} \geq r} P(\tilde{r})$ 。VOC 2010 及以后的积分法：

$$AP = \sum_{k=1}^M P_{\text{smooth}}(r_k) \cdot \Delta r_k \quad (4-18)$$

其中 $P_{\text{smooth}}(r_k)$ 是平滑后的 PR 曲线（保证单调递减）， Δr_k 是召回率区间的宽度。

(2) 全类平均精度（mAP）：mAP 是所有类别 AP 的算术平均值，公式为：

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (4-19)$$

其中 N 为类别总数。计算步骤如下：

- 1) 预测框排序：对每个类别的预测框按置信度降序排列，得到序列 $\{B_j\}$ 。
- 2) 计算 TP/FP：对每个预测框 B_j ，判断是否为真阳性（TP）或假阳性（FP）：若与真实框的 IoU $\geq$ 阈值（如 0.5），则标记为 TP；否则标记为 FP。
- 3) 生成 PR 曲线：累积计算每个点的精确率（Precision）和召回率（Recall）：

$$\text{Precision} = \frac{\sum TP}{\sum TP + \sum FP}, \quad \text{Recall} = \frac{\sum TP}{\sum GT} \quad (4-20)$$

其中 $\sum GT$ 是真实框总数。

- 4) 计算 AP：使用上述定义中的 11 点插值法或积分法计算 AP。
- 5) 计算 mAP：对所有类别的 AP 取平均。

不同数据集计算 mAP 存在差异，PASCAL VOC 使用单一 IoU 阈值（如 0.5），即

mAP@0.5。而 COCO 采用多阈值平均法，计算 IoU 从 0.5 到 0.95（步长 0.05）的 AP 均值，即 mAP@[0.5:0.95]。本章采用 COCO 的 mAP 计算方式。

表 4-1 使用不同方法攻击 YOLOv3 检测器的 mAP 指标

Benign	mAP	0.521	0.662	0.622	0.656	0.591	0.717	0.584	0.623	-
模型	Backbone 攻击	D-53 YOLOv3	R-50 VFNet	R-101 FRCNN	Swin MRCNN	R-50 YOLOF	CSPD YOLOX	R-50 FCOS	R-50 DETR	均值
YOLOv3	NRDM	0.009	0.271	0.296	0.359	0.243	0.243	0.244	0.248	0.272
	FDA	0.001	0.319	0.336	0.416	0.285	0.352	0.277	0.318	0.329
	NAA	0.012	0.326	0.326	0.385	0.284	0.298	0.275	0.319	0.319
	RPA	0.004	0.296	0.316	0.372	0.259	0.271	0.247	0.296	0.296
	TOG	0.004	0.375	0.376	0.446	0.332	0.395	0.320	0.370	0.373
	EFDA _{DIM}	0.000	0.139	0.166	0.223	0.129	0.122	0.127	0.142	0.150
	EFDA _{SRR}	0.000	0.105	0.125	0.169	0.093	0.112	0.095	0.107	0.101

表 4-2 使用不同方法攻击 VFNet 检测器的 mAP 指标

模型	Backbone 攻击	D-53 YOLOv3	R-50 VFNet	R-101 FRCNN	Swin MRCNN	R-50 YOLOF	CSPD YOLOX	R-50 FCOS	R-50 DETR	均值
VFNet	NRDM	0.195	0.010	0.096	0.273	0.066	0.257	0.062	0.019	0.138
	FDA	0.111	0.000	0.022	0.201	0.099	0.202	0.010	0.001	0.079
	NAA	0.187	0.007	0.087	0.247	0.066	0.269	0.053	0.022	0.133
	RPA	0.170	0.005	0.053	0.223	0.035	0.249	0.027	0.011	0.109
	TOG	0.283	0.006	0.168	0.372	0.130	0.405	0.105	0.046	0.215
	EFDA _{DIM}	0.085	0.000	0.014	0.125	0.005	0.124	0.006	0.001	0.051
	EFDA _{SRR}	0.065	0.000	0.012	0.088	0.004	0.119	0.005	0.001	0.042

表 4-3 使用不同方法攻击 FRCNN 检测器的 mAP 指标

模型	Backbone 攻击	D-53 YOLOv3	R-50 VFNet	R-101 FRCNN	Swin MRCNN	R-50 YOLOF	CSPD YOLOX	R-50 FCOS	R-50 DETR	均值
FRCNN	NRDM	0.180	0.043	0.002	0.320	0.035	0.352	0.034	0.065	0.147
	FDA	0.104	0.007	0.000	0.192	0.044	0.254	0.003	0.018	0.083
	NAA	0.155	0.056	0.003	0.224	0.046	0.284	0.044	0.067	0.125
	RPA	0.135	0.034	0.002	0.190	0.029	0.260	0.026	0.044	0.103
	TOG	0.173	0.038	0.000	0.254	0.032	0.336	0.024	0.058	0.130
	EFDA _{DIM}	0.080	0.000	0.000	0.132	0.002	0.176	0.002	0.009	0.058
	EFDA _{SRR}	0.049	0.001	0.000	0.077	0.001	0.144	0.001	0.044	0.039

表 4-4 使用不同方法攻击 MRCNN 检测器的 mAP 指标

模型	Backbone 攻击	D-53 YOLOv3	R-50 VFNet	R-101 FRCNN	Swin MRCNN	R-50 YOLOF	CSPD YOLOX	R-50 FCOS	R-50 DETR	均值
MRCNN	NRDM	0.111	0.100	0.147	0.003	0.107	0.195	0.109	0.095	0.123
	FDA	0.360	0.448	0.469	0.088	0.427	0.549	0.403	0.405	0.437
	NAA	0.147	0.147	0.175	0.005	0.147	0.207	0.137	0.135	0.156
	RPA	0.114	0.100	0.120	0.002	0.099	0.155	0.093	0.085	0.109
	TOG	0.128	0.107	0.137	0.000	0.113	0.170	0.099	0.104	0.123
	EFDA _{DIM}	0.084	0.064	0.105	0.002	0.075	0.132	0.080	0.059	0.085
	EFDA _{SRR}	0.039	0.035	0.055	0.001	0.063	0.113	0.042	0.032	0.054

4.4.5 攻击结果可视化分析

可视化本研究提出的 $EFDA_{SRR}$ 攻击生成的对抗样本，以及在各种白盒、黑盒模型上的检测结果，如图4-4、4-9和4-10所示。结果表明， $EFDA_{SRR}$ 攻击生成的对抗样本成功地抑制了白盒检测器中原始目标对象的检测，同时在对象及其周围区域生成了大量边界框。在将对抗样本迁移攻击其他黑盒模型时，尽管可能不会一直在对象周围生成大量检测框，但由于对对象及其周围区域应用的扰动策略，原始对象总能成功地逃避检测。显著特征通常对应于图像中较大对象的特定部分，而周围区域的邻近特征可能对应于原始对象的其他部分。在这种情况下，损失函数的抑制和放大效应导致来自较大对象不同部分的特征错位，从而将大对象的检测边界框分解为多个较小的边界框。对于较小的对象，显著特征通常代表整个对象。另一方面，本研究的攻击倾向于抑制原始检测边界框，并在其周围生成额外的边界框。

4.4.6 性能比较与分析

可迁移性比较：

评估了由本文的方法在 YOLOv3、VFNet、FasterRCNN 和 MaskRCNN 上生成的对抗样本的 mAP。如表4-4所示， $EFDA_{DIM}$ 方法（包括本文设计的损失函数和 DIM）已经在四个源模型上生成的对抗样本的有效性方面超越了其他比较攻击，无论是白盒攻击还是黑盒攻击。 $EFDA_{SRR}$ 用本章的数据增强方法 SRR 替换 DIM，进一步展示了其显著的黑盒对抗转移效果。

NRDM 可以被视为 $EFDA_{DIM}$ 方法的一个特例，其中良性特征的放大参数设置为 $k = 1$ 。NRDM 的可迁移攻击结果明显不如 $EFDA_{DIM}$ ，这也证明了抑制显著特征的必要性。尽管 FDA 在 VFNet 和 Faster-RCNN 上取得了良好的转移结果，但其对检测器的通用性仍然是一个不可忽视的问题。FDA 使用跨通道均值作为区分正负属性的标准，这在处理可能包含负值的 YOLOv3 特征时缺乏精确性。NAA 和 RPA 是基于梯度聚合的方法，它们在获取精确梯度时会产生前向-后向成本，并在复杂的检测器模型结构中




图 4-9 不同模型的黑盒迁移攻击结果 (a)




图 4-10 不同模型的黑盒迁移攻击结果 (b)

遭受过拟合问题。因此，它们在像 YOLOv3 这样的模型上表现出较弱的对抗转移结果。TOG 方法通过最大化训练损失来实现无目标攻击，但由于颈部和头部结构及参数的影响，也容易过拟合。TOG 在攻击四个模型时通常显示出比 NRDM 更差的可转移性结果，这表明专注于攻击特征层可以减少信息干扰并带来更好的转移性能。此外，表4-4显示了具有 ResNet 系列主干的检测器之间对抗样本的高度自然可转移性。例如，所有攻击在 VFNet 上的对抗样本可以很好地转移到具有 ResNet50 主干的目标检测器上，这表明尽管检测器颈部和头部结构存在差异，但具有相似主干的检测器共享相似的漏洞。

图4-11显示了不同目标检测器作为白盒模型时生成对抗样本的损失函数值变化，其中代表 FRCNN 的红色三角曲线的值较大，因此使用右侧纵坐标轴，其余三个模型的损失值使用左侧的纵坐标轴。




图 4-11 使用 EFDA 攻击不同模型的损失函数值变化

4.4.7 消融实验

为了研究数据增强对 $EFDA_{SRR}$ 的影响，在 FasterRCNN 上进行了消融实验，如表4-5所示。从 $EFDA_{SRR}$ 中移除了 SRR 数据增强方法，只保留了损失函数和 MIM，如表 2 的第二行结果所示。在这种情况下，设计的损失函数将抑制对抗样本的所有特征。缺乏对邻近特征的放大阻碍了其在表4-4中相对于比较方法的黑盒可转移性性能，突显了扰动对象周围区域的重要性。

为了评估 SRR 中每个组件对对抗攻击的个体贡献，通过移除其中一个组件同时保留其他三个来进行实验。实验结果表明，在迁移攻击能力评估中，网格打乱 > 旋转 > 调整大小，黑盒迁移攻击能力依次降低。可以解释为，在对 YOLOv3 的攻击中，网格打乱操作不仅保持了对重要特征的抑制，而且使得邻近非重要特征获得了更多的关注。考虑到这几种增强模式的特异性，SRR 方法并行整合了三者以实现更大的多样性，并再次之后进行高斯模糊。高斯模糊是一种辅助方法，通过向图片引入噪声来进一步干扰全局特征。实验结果表明，在消融它之后，生成的对抗样本在黑盒模型上的对抗可转移性有所下降。

4.5 本章小结

考虑到检测器骨干特征的空间一致性和有限的等变性，本章提出了一种新型目标检测对抗攻击算法——基于增强特征失真的可迁移对抗攻击，用于对不同黑盒模型进

表 4-5 EFDA 输入变换消融实验

Ablation	YOLOv3	FRCNN	VFNet	MRCNN	YOLOF	YOLOX	FCOS	DETR	Mean
baseline	0.000	0.125	0.105	0.169	0.093	0.112	0.095	0.107	0.101
w/o SRR	0.000	0.534	0.410	0.359	0.224	0.340	0.260	0.412	0.317
w/o Shuffle	0.000	0.245	0.201	0.247	0.134	0.210	0.165	0.341	0.193
w/o Resizing	0.000	0.311	0.340	0.269	0.263	0.248	0.174	0.347	0.244
w/o Rotation	0.000	0.250	0.246	0.314	0.208	0.198	0.273	0.241	0.216
w/o Blurring	0.000	0.164	0.364	0.299	0.179	0.294	0.176	0.283	0.220

行无目标对抗攻击。该算法由两部分组成：双路径特征失真度量框架和基于 SRR 的输入变换。前者定义了一个包含幅度失真项和方向失真项的损失函数，衡量对抗样本和原始图像之间在目标检测网络 Backbone 中间层特征的差异，通过增强这种差异实现迁移攻击。后者定义了四种图像变换方式，包括随机网格打乱、随机轴旋转、自适应随机大小调整和高斯模糊，通过对对抗样本使用不同的输入变换，扭曲对象重要特征，从而增强黑盒攻击能力。

实验证明，EFDA 相对于多个基线方法在不同黑盒模型上实现了 SOTA 攻击性能。除此之外，本章还对生成的对抗样本使用 Grad-CAM 方法进行可解释分析，为理解深度视觉系统的脆弱性提供了新的理论视角，进一步证明了本章提出的攻击具有强大的迁移攻击能力。最后通过消融实验验证了 SRR 方法中各种输入变换方法的有效性。

5 总结与展望

5.1 全文总结

尽管基于深度神经网络的人工智能模型在计算机视觉领域得到了广泛的应用，深度神经网络仍然容易收到对抗样本的影响。通过在原始图像上的微小扰动生成对抗样本，人类很难区分对抗样本和真实样本的区别，但这种对抗样本会导致模型产生错误的预测。这种对抗攻击对深度神经网络在安全敏感的应用程序中的部署构成了验证威胁。为了进一步了解对抗样本的生成机理，评估深度模型的鲁棒性和安全性，本文针对图像分类和目标检测两种不同的计算机视觉任务，对依赖不同任务的对抗样本进行了研究，并针对性的提出了具有强大迁移性的对抗攻击算法：基于快速平坦近邻采样的图像分类可迁移对抗攻击和基于增强特征失真的目标检测可迁移对抗攻击。

在图像分类可迁移对抗攻击部分，本研究基于平坦局部极大值理论，提出了快速平坦近邻采样对抗攻击 **FFSA**，从惩罚梯度范数的角度出发优化梯度，促使对抗样本达到白盒模型损失的平坦局部极大值。针对已有算法容易过拟合和计算复杂度高的问题，首先简化了每个迭代中随机采样平均梯度的计算方式，每次随机采样只计算一次梯度信息，用上一次迭代的梯度来寻找当前随机采样点，同时对每次随机采样点周围子区域的上界进行随机调整，避免了固定上界造成的邻域信息损失。此外 **FFSA** 还可以和基于输入变换的攻击相结合进一步增强迁移能力。实验数据表明，**FFSA** 相比 **PGN** 和其他基线方法实现了更高的黑盒迁移攻击成功率，通过对实验结果的可视化发现这样的对抗样本所在区域位于损失平坦局部极大值，进一步验证了方法有效性。

在目标检测可迁移对抗攻击部分，本研究基于检测器的空间一致性和有限等变性理论，提出了基于增强特征失真的可迁移对抗攻击 **EFDA**，可生成用于无目标攻击的对抗样本。**EFDA** 包括两部分：双路径特征失真度量框架和基于 **SRR** 的输入变换。前者定义了一个包含幅度失真项和方向失真项的损失函数，衡量对抗样本和原始图像之间在检测器 **Backbone** 中间层特征的差异，通过增强这种差异实现迁移攻击。后者者定义了四种图像变换方式，包括随机网格打乱、随机轴旋转、自适应随机大小调整和高斯模糊，通过使用不同的输入变换，扭曲对象重要特征。实验数据表明，**EFDA** 相比其他基线攻击方法，不论是基于特征的攻击还是基于损失函数的目标检测攻击 **TOG**，对于黑盒模型的攻击效果都更好。最后通过生成对抗样本的注意力热力图，从可解释角度分析了为什么这样的对抗样本迁移能力强大。

FFSA 迁移攻击和 **EFDA** 迁移攻击两种算法分别从图像分类对抗样本和目标检测对抗样本两个角度研究了对抗样本的迁移性，前者从梯度优化角度出发增强迁移性，后者从损失函数设计和输入变换角度为目标检测任务设计对抗攻击，两者互为补充，共同构成了一个强大的黑盒迁移攻击框架，能够对常见的图像分类模型和目标检测模型的鲁棒性进行评估，为安全敏感领域深度学习的应用提供了可靠的安全性分析手段。

5.2 未来工作展望

尽管本文提出的两种攻击算法迁移能力方面表现优秀，但在实际应用中依然存在一些问题，需要未来对其进行深入研究进行解决。

首先，对于 FFSA 对抗攻击，在基于 CNN 的分类模型上迁移能力较强，在基于 Transformer 的分类模型上迁移能力仍有待提高，这表明对于不同模型架构的神经网络，其可迁移对抗样本的生成和可解释性依然存在较大研究的空间。其次，对于 EFDA 对抗攻击，目前只在数字世界实现了强大的攻击，这样生成的对抗样本是否能在部署在物理世界后仍具有迁移攻击能力需要进行进一步的研究。

致 谢

致 谢

参考文献

- [1] Szegedy C, Zaremba W, Sutskever I, et al. Intriguing properties of neural networks[J]. arXiv preprint arXiv:1312.6199. 2013.
- [2] Kurakin A, Goodfellow I J, Bengio S. Adversarial examples in the physical world [M]: Chapman and Hall/CRC, 2018: 99–112.
- [3] Madry A, Makelov A, Schmidt L, et al. Towards deep learning models resistant to adversarial attacks[J]. arXiv preprint arXiv:1706.06083. 2017.
- [4] Moosavi-Dezfooli S M, Fawzi A, Frossard P. Deepfool: a simple and accurate method to fool deep neural networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 2574–2582.
- [5] Carlini N, Wagner D. Towards evaluating the robustness of neural networks[C]// Ieee. 2017 ieee symposium on security and privacy (sp): Ieee, 2017: 39–57.
- [6] Moosavi-Dezfooli S M, Fawzi A, Fawzi O, et al. Universal adversarial perturbations[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 1765–1773.
- [7] Papernot N, McDaniel P, Goodfellow I. Transferability in machine learning: from phenomena to black-box attacks using adversarial samples[J]. arXiv preprint arXiv:1605.07277. 2016.
- [8] Brendel W, Rauber J, Bethge M. Decision-based adversarial attacks: Reliable attacks against black-box machine learning models[J]. arXiv preprint arXiv:1712.04248. 2017.
- [9] Tramèr F, Kurakin A, Papernot N, et al. Ensemble adversarial training: Attacks and defenses[J]. arXiv preprint arXiv:1705.07204. 2017.
- [10] Uesato J, O’ donoghue B, Kohli P, et al. Adversarial risk and the dangers of evaluating against weak attacks[C]// PMLR. International conference on machine learning: PMLR, 2018: 5025–5034.
- [11] Kingma D P, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980. 2014.
- [12] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556. 2014.
- [13] Xie C, Zhang Z, Zhou Y, et al. Improving transferability of adversarial examples with input diversity[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 2730–2739.
- [14] Lin J, Song C, He K, et al. Nesterov accelerated gradient and scale invariance for adversarial attacks[J]. arXiv preprint arXiv:1908.06281. 2019.
- [15] Wang X, He X, Wang J, et al. Admix: Enhancing the transferability of adversarial attacks[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2021: 16158–16167.
- [16] Dong Y, Pang T, Su H, et al. Evading defenses to transferable adversarial examples by translation-invariant attacks[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 4312–4321.
- [17] Dong Y, Liao F, Pang T, et al. Boosting adversarial attacks with momentum[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 9185–9193.
- [18] Wang X, He K. Enhancing the transferability of adversarial attacks through variance tuning[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021: 1924–1933.
- [19] Wu D, Wang Y, Xia S T, et al. Skip connections matter: On the transferability of adversarial examples generated with resnets[J]. arXiv preprint arXiv:2002.05990. 2020.

-
- [20] Huang Q, Katsman I, He H, et al. Enhancing adversarial example transferability with an intermediate level attack[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2019: 4733–4742.
- [21] Inkawhich N, Liang K J, Carin L, et al. Transferable perturbations of deep feature distributions[J]. arXiv preprint arXiv:2004.12519. 2020.
- [22] Ganeshan A, BS V, Babu R V. Fda: Feature disruptive attack[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 8069–8079.
- [23] Zhao Z, Liu Z, Larson M. On success and simplicity: A second look at transferable targeted attacks[J]. Advances in Neural Information Processing Systems. 2021, 34:6115–6128.
- [24] Zhang H, Zhou W, Li H. Contextual adversarial attacks for object detection[C]// IEEE. 2020 IEEE international conference on multimedia and expo (ICME): IEEE, 2020: 1–6.
- [25] Naseer M, Khan S H, Rahman S, et al. Task-generalizable adversarial attack based on perceptual metric[J]. arXiv preprint arXiv:1811.09020. 2018.
- [26] Lu Y, Du X, Sun B, et al. Fabricate-vanish: An effective and transferable black-box adversarial attack incorporating feature distortion[C]// IEEE. 2021 IEEE International Conference on Image Processing (ICIP): IEEE, 2021: 809–813.
- [27] Wang Z, Guo H, Zhang Z, et al. Feature importance-aware transferable adversarial attacks[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2021: 7639–7648.
- [28] Zhang Y, Tan Y a, Chen T, et al. Enhancing the transferability of adversarial examples with random patch.[C]. IJCAI: volume 8, 2022: 13.
- [29] Zhang J, Wu W, Huang J t, et al. Improving adversarial transferability via neuron attribution-based attacks[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 14993–15002.
- [30] Naseer M M, Khan S H, Khan M H, et al. Cross-domain transferability of adversarial perturbations[J]. Advances in Neural Information Processing Systems. 2019, 32.
- [31] Poursaeed O, Katsman I, Gao B, et al. Generative adversarial perturbations[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 4422–4431.
- [32] Naseer M, Khan S, Hayat M, et al. On generating transferable targeted perturbations[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021: 7708–7717.
- [33] Chang C C, Lin C J. Libsvm: a library for support vector machines[J]. ACM transactions on intelligent systems and technology (TIST). 2011, 2(3):1–27.
- [34] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 2117–2125.
- [35] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 8759–8768.
- [36] Tan M, Pang R, Le Q V. Efficientdet: Scalable and efficient object detection[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 10781–10790.
- [37] Jiang Y, Tan Z, Wang J, et al. Giraffedet: A heavy-neck paradigm for object detection[J]. arXiv preprint arXiv:2202.04256. 2022.
- [38] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2014: 580–587.
- [39] Uijlings J R, Van De Sande K E, Gevers T, et al. Selective search for object recognition[J]. International journal of computer vision. 2013, 104:154–171.

- [40] Girshick R. Fast r-cnn[C]. Proceedings of the IEEE international conference on computer vision, 2015: 1440–1448.
- [41] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence. 2015, 37(9):1904–1916.
- [42] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems. 2015, 28.
- [43] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767. 2018.
- [44] Xie C, Wang J, Zhang Z, et al. Adversarial examples for semantic segmentation and object detection[C]. Proceedings of the IEEE international conference on computer vision, 2017: 1369–1378.
- [45] Li Y, Tian D, Chang M C, et al. Robust adversarial perturbation on deep proposal-based models[J]. arXiv preprint arXiv:1809.05962. 2018.
- [46] Wei X, Liang S, Chen N, et al. Transferable adversarial attacks for image and video object detection[J]. arXiv preprint arXiv:1811.12641. 2018.
- [47] Chow K H, Liu L, Loper M, et al. Adversarial objectness gradient attacks in real-time object detection systems[C]// IEEE. 2020 Second IEEE International Conference on Trust, Privacy and Security in Intelligent Systems and Applications (TPS-ISA): IEEE, 2020: 263–272.
- [48] Cai Z, Xie X, Li S, et al. Context-aware transfer attacks for object detection[C]. Proceedings of the AAAI Conference on Artificial Intelligence: volume 36, 2022: 149–157.
- [49] Cai Z, Rane S, Brito A E, et al. Zero-query transfer attacks on context-aware object detectors[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 15024–15034.
- [50] Lu Y, Jia Y, Wang J, et al. Enhancing cross-task black-box transferability of adversarial examples with dispersion reduction[C]. Proceedings of the IEEE/CVF conference on Computer Vision and Pattern Recognition, 2020: 940–949.
- [51] Wei Z, Chen J, Wu Z, et al. Cross-modal transferable adversarial attacks from images to videos[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 15064–15073.
- [52] Naseer M, Mahmood A, Khan S, et al. Boosting adversarial transferability using dynamic cues[C]. The Eleventh International Conference on Learning Representations, 2023.
- [53] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[J]. arXiv preprint arXiv:1412.6572. 2014.
- [54] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. nature. 1986, 323(6088):533–536.
- [55] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 779–788.
- [56] Han S, Lin C, Shen C, et al. Interpreting adversarial examples in deep learning: A review[J]. ACM Computing Surveys. 2023, 55(14s):1–38.
- [57] Li H, Fan Y, Ganz F, et al. Verifying the causes of adversarial examples[C]// IEEE. 2020 25th International Conference on Pattern Recognition (ICPR): IEEE, 2021: 6750–6757.
- [58] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 770–778.

-
- [59] Nar K, Ocal O, Sastry S S, et al. Cross-entropy loss and low-rank features have responsibility for adversarial examples[J]. arXiv preprint arXiv:1901.08360. 2019.
- [60] Deniz O, Pedraza A, Vallez N, et al. Robustness to adversarial examples can be improved with overfitting[J]. International Journal of Machine Learning and Cybernetics. 2020, 11:935–944.
- [61] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]// pmlr. International conference on machine learning: pmlr, 2015: 448–456.
- [62] Galloway A, Golubeva A, Tanay T, et al. Batch normalization is a cause of adversarial vulnerability[J]. arXiv preprint arXiv:1905.02161. 2019.
- [63] Tanay T, Griffin L. A boundary tilting perspective on the phenomenon of adversarial examples[J]. arXiv preprint arXiv:1608.07690. 2016.
- [64] Tramèr F, Papernot N, Goodfellow I, et al. The space of transferable adversarial examples[J]. arXiv preprint arXiv:1704.03453. 2017.
- [65] Che Z, Borji A, Zhai G, et al. A new ensemble adversarial attack powered by long-term gradient memories[C]. Proceedings of the AAAI conference on artificial intelligence: volume 34, 2020: 3405–3413.
- [66] Simon-Gabriel C J, Ollivier Y, Bottou L, et al. First-order adversarial vulnerability of neural networks and input dimension[C]// PMLR. International conference on machine learning: PMLR, 2019: 5809–5817.
- [67] Gorban A N, Golubkov A, Grechuk B, et al. Correction of ai systems by linear discriminants: Probabilistic foundations[J]. Information Sciences. 2018, 466:303–322.
- [68] Shafahi A, Huang W R, Studer C, et al. Are adversarial examples inevitable?[J]. arXiv preprint arXiv:1809.02104. 2018.
- [69] Dohmatob E. Limitations of adversarial robustness: strong no free lunch theorem[J]. arXiv preprint arXiv:1810.04065. 2018, 8.
- [70] Grosse K, Manoharan P, Papernot N, et al. On the (statistical) detection of adversarial examples[J]. arXiv preprint arXiv:1702.06280. 2017.
- [71] Shamir A, Safran I, Ronen E, et al. A simple explanation for the existence of adversarial examples with small hamming distance[J]. arXiv preprint arXiv:1901.10861. 2019.
- [72] Li H, Fan Y, Ganz F, et al. Verifying the causes of adversarial examples[C]// IEEE. 2020 25th International Conference on Pattern Recognition (ICPR): IEEE, 2021: 6750–6757.
- [73] Wang Y, Jha S, Chaudhuri K. Analyzing the robustness of nearest neighbors to adversarial examples[C]// PMLR. International Conference on Machine Learning: PMLR, 2018: 5133–5142.
- [74] Stutz D, Hein M, Schiele B. Disentangling adversarial robustness and generalization[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 6976–6987.
- [75] Mao C, Zhong Z, Yang J, et al. Metric learning for adversarial robustness[J]. Advances in neural information processing systems. 2019, 32.
- [76] Xie C, Wu Y, Maaten L v d, et al. Feature denoising for improving adversarial robustness[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 501–509.
- [77] Yang P, Chen J, Hsieh C J, et al. MI-loo: Detecting adversarial examples with feature attribution[C]. Proceedings of the AAAI Conference on Artificial Intelligence: volume 34, 2020: 6639–6647.
- [78] Ribeiro M T, Singh S, Guestrin C. ” why should i trust you?” explaining the predictions of any classifier[C]. Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining, 2016: 1135–1144.

- [79] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[J]. Advances in neural information processing systems. 2017, 30.
- [80] Agarwal C, Nguyen A, Schonfeld D. Improving robustness to adversarial examples by encouraging discriminative features[C]// IEEE. 2019 IEEE International Conference on Image Processing (ICIP): IEEE, 2019: 3801–3505.
- [81] Mustafa A, Khan S, Hayat M, et al. Adversarial defense by restricting the hidden space of deep neural networks[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2019: 3385–3394.
- [82] Liu C, Jaja J. Feature prioritization and regularization improve standard accuracy and adversarial robustness[J]. arXiv preprint arXiv:1810.02424. 2018.
- [83] Qin Z, Fan Y, Liu Y, et al. Boosting the transferability of adversarial attacks with reverse adversarial perturbation[J]. Advances in neural information processing systems. 2022, 35:29845–29858.
- [84] Liu R, Gao J, Zhang J, et al. Investigating bi-level optimization for learning and vision from a unified perspective: A survey and beyond[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence. 2021, 44(12):10045–10067.
- [85] Hochreiter S, Schmidhuber J. Flat minima[J]. Neural computation. 1997, 9(1):1–42.
- [86] Keskar N S, Mudigere D, Nocedal J, et al. On large-batch training for deep learning: Generalization gap and sharp minima[J]. arXiv preprint arXiv:1609.04836. 2016.
- [87] Neyshabur B, Bhojanapalli S, McAllester D, et al. Exploring generalization in deep learning[J]. Advances in neural information processing systems. 2017, 30.
- [88] Foret P, Kleiner A, Mobahi H, et al. Sharpness-aware minimization for efficiently improving generalization[J]. arXiv preprint arXiv:2010.01412. 2020.
- [89] Zhao Y, Zhang H, Hu X. Penalizing gradient norm for efficiently improving generalization in deep learning[C]// PMLR. International conference on machine learning: PMLR, 2022: 26982–26992.
- [90] Li H, Xu Z, Taylor G, et al. Visualizing the loss landscape of neural nets[J]. Advances in neural information processing systems. 2018, 31.
- [91] Santurkar S, Tsipras D, Ilyas A, et al. How does batch normalization help optimization?[J]. Advances in neural information processing systems. 2018, 31.
- [92] Jiang Y, Neyshabur B, Mobahi H, et al. Fantastic generalization measures and where to find them[J]. arXiv preprint arXiv:1912.02178. 2019.
- [93] Ge Z, Liu H, Xiaosen W, et al. Boosting adversarial transferability by achieving flat local maxima[J]. Advances in Neural Information Processing Systems. 2023, 36:70141–70161.
- [94] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556. 2014.
- [95] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 4510–4520.
- [96] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2021: 10012–10022.
- [97] Wang W, Xie E, Li X, et al. Pyramid vision transformer: A versatile backbone for dense prediction without convolutions[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2021: 568–578.

-
- [98] Ghiasi G, Lin T Y, Le Q V. Nas-fpn: Learning scalable feature pyramid architecture for object detection[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 7036–7045.
- [99] Wang J, Chen K, Xu R, et al. Carafe: Content-aware reassembly of features[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2019: 3007–3016.
- [100] Zeiler M D, Fergus R. Visualizing and understanding convolutional networks[C]// Springer. Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part I 13: Springer, 2014: 818–833.
- [101] Zhou W, Hou X, Chen Y, et al. Transferable adversarial perturbations[C]. Proceedings of the European Conference on Computer Vision (ECCV), 2018: 452–467.
- [102] Perronnin F, Sánchez J, Mensink T. Improving the fisher kernel for large-scale image classification[C]// Springer. Computer Vision–ECCV 2010: 11th European Conference on Computer Vision, Heraklion, Crete, Greece, September 5-11, 2010, Proceedings, Part IV 11: Springer, 2010: 143–156.
- [103] Kupyn O, Budzan V, Mykhailych M, et al. Deblurgan: Blind motion deblurring using conditional adversarial networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 8183–8192.
- [104] Xu K, Ba J, Kiros R, et al. Show, attend and tell: Neural image caption generation with visual attention[C]// PMLR. International conference on machine learning: PMLR, 2015: 2048–2057.
- [105] Vinyals O, Toshev A, Bengio S, et al. Show and tell: Lessons learned from the 2015 mscoco image captioning challenge[J]. IEEE transactions on pattern analysis and machine intelligence. 2016, 39 (4):652–663.
- [106] Gatys L A, Ecker A S, Bethge M. Image style transfer using convolutional neural networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 2414–2423.
- [107] Hammer P. Adaptive control processes: a guided tour (R. Bellman) [M]: Society for Industrial and Applied Mathematics, 1962.
- [108] Zhang H, Wang Y, Dayoub F, et al. Varifocalnet: An iou-aware dense object detector[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021: 8514–8523.
- [109] He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]. Proceedings of the IEEE international conference on computer vision, 2017: 2961–2969.
- [110] Chen Q, Wang Y, Yang T, et al. You only look one-level feature[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021: 13039–13048.
- [111] Ge Z, Liu S, Wang F, et al. YOLOX: Exceeding yolo series in 2021[J]. arXiv preprint arXiv:2107.08430. 2021.
- [112] Tian Z, Shen C, Chen H, et al. Fcos: Fully convolutional one-stage object detection[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2019: 9627–9636.
- [113] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C]// Springer. European conference on computer vision: Springer, 2020: 213–229.

攻读学位期间取得的研究成果

[1]

答辩委员会会议决议

常规评阅人名单

本学位论文共接受 2 位专家评阅，其中常规评阅人 1 名，名单如下：

肖帅

研究员

阿里巴巴

学位论文独创性声明 (1)

本人声明：所呈交的学位论文系在导师指导下本人独立完成的研究成果。文中依法引用他人的成果，均已做出明确标注或得到许可。论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 交回学校授予的学位证书；
2. 学校可在相关媒体上对作者本人的行为进行通报；
3. 本人按照学校规定的方式，对因不当取得学位给学校造成的名誉损害，进行公开道歉；
4. 本人负责因论文成果不实产生的法律纠纷。

论文作者 (签名): _____ 日期: _____ 年 _____ 月 _____ 日

学位论文独创性声明 (2)

本人声明：研究生_____所提交的本篇学位论文已经本人审阅，确系在本人指导下由该生独立完成的研究成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 学校可在相关媒体上对本人的失察行为进行通报；
2. 本人按照学校规定的方式，对因失察给学校造成的名誉损害，进行公开道歉；
3. 本人接受学校按照有关规定做出的任何处理。

指导教师 (签名): _____ 日期: _____ 年 _____ 月 _____ 日

学位论文知识产权权属声明

我们声明，我们提交的学位论文及相关的职务作品，知识产权归属学校。学校享有以任何方式发表、复制、公开阅览、借阅以及申请专利等权利。学位论文作者离校后，或学位论文导师因故离校后，发表或使用学位论文或与该论文直接相关的学术论文或成果时，署名单位仍然为西安交通大学。

论文作者 (签名): _____ 日期: _____ 年 _____ 月 _____ 日

指导教师 (签名): _____ 日期: _____ 年 _____ 月 _____ 日

(本声明的版权归西安交通大学所有，未经许可，任何单位及任何个人不得擅自使用)